

EWMA = Exponentially Weighted Moving Average
ou Método de Ajustamento Exponencial Simples

↳ Ideia: construir previsões através de soma ponderada das observações, dando maior peso às obs. mais recentes.

Método de previsão ⇒ fórmula matemática usada para construir previsões (não é um modelo estatístico pois não possui componente aleatório).

Exs:

1) Método ingênuo (ou naïve)

$\hat{y}_{t+1|t} = y_t \rightarrow$ a previsão para amanhã é o valor de hoje

⇓
daí, peso 1 a obs mais recente e peso 0 a todas as outras, pois?

$$\hat{y}_{t+1|t} = \sum_{j=0}^{t-1} w_j y_{t-j} = \underbrace{w_0}_{1} y_t + \underbrace{w_1}_{0} y_{t-1} + \dots + \underbrace{w_{t-2}}_{0} y_2 + \underbrace{w_{t-1}}_{0} y_1$$

Consistente com o modelo de passeio aleatório:

$$y_t = y_{t-1} + \varepsilon_t \Rightarrow \hat{y}_{t+1|t} = E(y_{t+1}|y_t) = y_t$$

Portanto o método ingênuo apenas faz sentido se a série estiver realmente de passeio aleatório, apresentando comportamento estocástico (séries não estacionárias) → consistente c/ $y_t = \alpha + \varepsilon_t$
↳ estacionária

II) média aritmética $\hat{y}_{t+1|t} = \frac{\sum_{j=0}^{t-1} y_{t-j}}{t} \Rightarrow$ todas as observações possuem o mesmo peso.


Portanto deve ser utilizado para séries bem comportadas, estacionárias

⇒

III) EWMA

$$\hat{y}_{t+1|t} = \sum_{j=0}^{t-1} w_j y_{t-j}$$

onde $w_j = (1-\lambda)^j \lambda$, $0 < \lambda < 1$ \rightarrow cto. de amortecimento



$$\hat{y}_{t+1|t} = \lambda \sum_{j=0}^{t-1} (1-\lambda)^j y_{t-j} = \lambda y_t + \underbrace{\sum_{j=1}^{t-1} \lambda (1-\lambda)^j y_{t-j}}_A$$

Mas $\hat{y}_{t+1|t-1} = (1-\lambda) \sum_{j=0}^{t-2} (1-\lambda)^j y_{t-1-j}$ $i = 1+j \begin{cases} \lambda^j \Rightarrow \lambda^{i-1} \\ y_{t-(1+j)} \Rightarrow y_{t-i} \\ t-2 \rightarrow t-1 \end{cases}$

$$\hat{y}_{t+1|t-1} = (1-\lambda) \sum_{i=1}^{t-1} (1-\lambda)^{i-1} y_{t-i} = (1-\lambda)^{-1} \lambda \sum_{i=1}^{t-1} (1-\lambda)^i y_{t-i}$$

$$(1-\lambda) \hat{y}_{t+1|t-1} = \sum_{i=1}^{t-1} \lambda (1-\lambda)^i y_{t-i} \Rightarrow \text{subs em (A)}$$

$$\hat{y}_{t+1|t} = \lambda y_t + (1-\lambda) \hat{y}_{t+1|t-1}, \quad 0 < \lambda < 1 \quad (I)$$

Para implementar na prática: $\hat{y}_{1|0} = \bar{y}$ (usando as primeiras $T/3$ observações)

II) Estimar λ minimizando $S(\lambda)$: utilize a fórmula (I) com $\lambda = 0.1, 0.2, 0.3, \dots$ e

$$S(\lambda) = \sum_{t=0}^{T-1} (y_{t+1} - \hat{y}_{t+1|t}(\lambda))^2$$

escolhe o λ que minimiza $S(\lambda)$.

ARIMA(0,1,1) e EWMA

II

$$\Rightarrow \Delta Y_t = \theta \varepsilon_{t-1} + \varepsilon_t, \quad |\theta| < 1, \quad \varepsilon_t \sim N(0, \sigma^2)$$

Queremos $\hat{Y}_{t+1|t} = E(Y_{t+1} | Y_t)$ e mostrar que essa função será EWMA

$$Y_t - Y_{t-1} = \theta \varepsilon_{t-1} + \varepsilon_t$$

$$Y_t = Y_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t \quad (II)$$

$$Y_{t+1} = Y_t + \theta \varepsilon_t + \varepsilon_{t+1}$$

$$\hat{Y}_{t+1|t} = E(Y_{t+1} | Y_t) = Y_t + \theta \varepsilon_t \quad (III)$$

Mes de (II) segue que $\hat{Y}_{t+1|t} = Y_{t+1} - \theta \varepsilon_{t+1}$, e que portanto $\varepsilon_t = Y_t - [Y_{t+1} - \theta \varepsilon_{t+1}] = Y_t - \hat{Y}_{t+1|t} \Rightarrow$ subs. em (III)

$$\hat{Y}_{t+1|t} = Y_t + \theta [Y_t - \hat{Y}_{t+1|t}]$$

$$\hat{Y}_{t+1|t} = (1+\theta)Y_t - \theta \hat{Y}_{t+1|t}$$

Se definirmos $1+\theta = \lambda$, como $\lambda \in (0,1) \Rightarrow \theta \in (-1,0)$

$$\hat{Y}_{t+1|t} = \lambda Y_t + (1-\lambda) \hat{Y}_{t+1|t}, \quad \lambda = 1+\theta, \quad \theta \in (-1,0)$$


ou seja, a função de previsão 1 passo à frente do ARIMA(0,1,1) é um EWMA, desde que $\theta \in (-1,0)$.

Para o ARIMA(0,1,1), mostra-se facilmente que

$$\hat{Y}_{t+k|t} = E(Y_{t+k} | Y_t) = \hat{Y}_{t+1|t} = \text{EWMA}(\theta, \theta \in (-1,0))$$

Logo o EWMA tem a mesma função de previsão

K-passos à frente, não apenas a 1 passo à frente.



Obs: Observamos que os pesos w_j em

$$1) \quad \hat{y}_{t+1|t} = \sum_{j=0}^{t-1} \underbrace{(1-\lambda)^j \lambda}_{w_j} y_{t+j} \quad \text{não somam 1,}$$

pois $\sum_{j=0}^{t-1} w_j = \lambda \underbrace{\sum_{j=0}^{t-1} (1-\lambda)^j}_{\text{PG decrescente}} = \lambda \left[\frac{1 - (1-\lambda)^t}{1 - (1-\lambda)} \right] = 1 - (1-\lambda)^t$

Definindo $\delta_j^t = \frac{w_j}{1 - (1-\lambda)^t} = \frac{(1-\lambda)^j \lambda}{1 - (1-\lambda)^t}$, então por construção $\sum_{j=0}^{t-1} \delta_j^t = 1$

Pesos que somam 1 facilitam a interpretação de previsões. Assim podemos obter um EWMA "normalizado"

$$\hat{y}_{t+1|t} = \sum_{j=0}^{t-1} \frac{(1-\lambda)^j \lambda}{[1 - (1-\lambda)^t]} y_{t+j} = \sum_{j=0}^{t-1} \delta_j^t y_{t+j} \quad (\text{IV})$$

$$\hat{y}_{t+1|t} = \frac{\lambda}{1 - (1-\lambda)^t} y_t + \sum_{j=1}^{t-1} \frac{\lambda (1-\lambda)^j}{[1 - (1-\lambda)^t]} y_{t+j}$$

Mes $\hat{y}_{t+1|t} = \sum_{j=0}^{t-2} \frac{(1-\lambda)^j \lambda}{1 - (1-\lambda)^{t-1}} y_{t-(1+j)}$

$$1+j=i \Rightarrow j=i-1$$

$$(1+j)=i$$

$$\text{Se } j=t-2 \Rightarrow i=t-2+1=t-1$$

$$j=0 \Rightarrow i=1$$

$$\hat{y}_{t+1|t} = \sum_{i=1}^{t-1} \frac{\lambda (1-\lambda)^{i-1}}{[1 - (1-\lambda)^{t-1}]} y_{t-i}$$

usando (IV)

$$\hat{y}_{t+1|t} = \frac{1}{(1-\lambda)} \sum_{i=1}^{t-1} \frac{\lambda (1-\lambda)^i}{[1 - (1-\lambda)^{t-1}]} y_{t-i}, \quad \text{donde segue que}$$

$$\sum_{i=1}^{t-1} \lambda (1-\lambda)^i y_{t-i} = (1-\lambda) [1 - (1-\lambda)^{t-1}] \hat{y}_{t+1|t} \quad (\text{B})$$

Como $\hat{y}_{t+1|t} = \frac{\lambda}{1-(1-\lambda)^t} y_t + \left[\sum_{j=1}^{t-1} \frac{\lambda(1-\lambda)^j}{1-(1-\lambda)^t} y_{t-j} \right] \xrightarrow{\text{Subst. (II)}} \text{por (B)}$

$$\hat{y}_{t+1|t} = \frac{\lambda}{1-(1-\lambda)^t} y_t + \frac{(1-\lambda) [1-(1-\lambda)^{t-1}]}{1-(1-\lambda)^t} \hat{y}_{t|t-1} \quad (\text{VI})$$

$$\frac{(1-\lambda) [1-(1-\lambda)^{t-1}]}{1-(1-\lambda)^t} = \frac{(1-\lambda) - (1-\lambda)^t}{1-(1-\lambda)^t}$$

Definindo $\lambda_t = \frac{\lambda}{1-(1-\lambda)^t}$

$$1 - \lambda_t = \frac{1-(1-\lambda)^t - \lambda}{1-(1-\lambda)^t} = \frac{(1-\lambda) - (1-\lambda)^t}{1-(1-\lambda)^t}$$

E assim, podemos re-escrever (VI) como

$$\hat{y}_{t+1|t} = \lambda_t y_t + (1 - \lambda_t) \hat{y}_{t|t-1}$$

Se t estiver muito distante da origem então $(1-\lambda)^t \rightarrow 0$
e assim $\lambda_t = \lambda$.

2) Se a série apresentar tendência crescente e/ou sazonalidade
então o EWMA deve ser substituído por métodos de aumento
crescente mais gerais: Holt e Holt-Winters. Ao se
utilizar esses métodos em séries não estacionárias não
será necessário transformar a série; aplica direto na série

