

Pontifícia Universidade Católica do Rio de Janeiro  
Departamento de Engenharia Elétrica

## **ENG 1469 - Análise de Séries Temporais**

Notas de aula  
(versão preliminar)


**Prof. Cristiano Fernandes**

*2013*

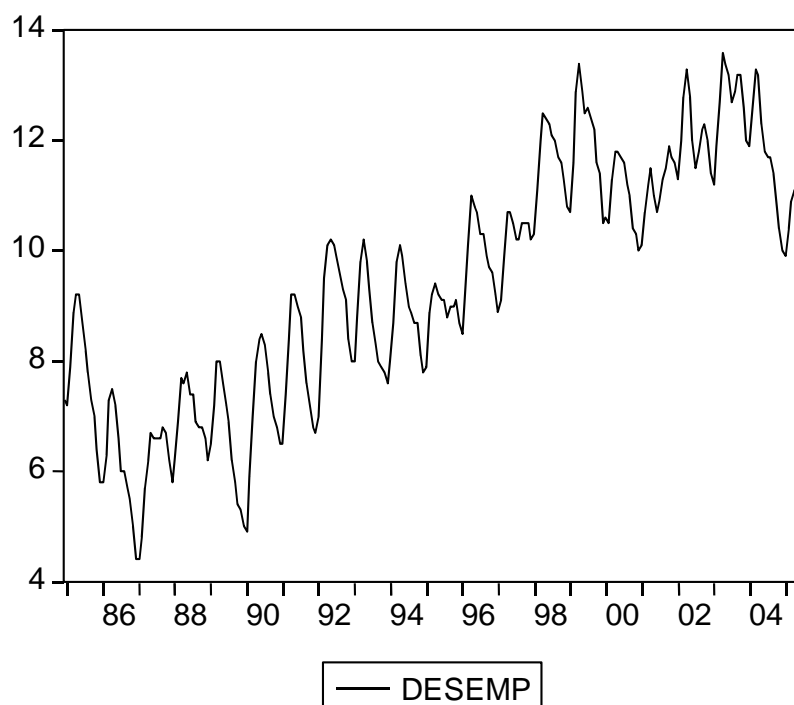
## Introdução e Motivação

- Uma **Série Temporal** (ST) é um conjunto de observações, geralmente equiespaçadas, obtidas a partir da medição/observação de uma variável ao longo do tempo.
- A frequência de observação/medição de uma ST pode variar dependendo do fenômeno observado: minuto, diária, semanal, mensal, anual etc.
- **Exemplos** de ST's:
  - Retornos diários das cotações do IBOVESPA;
  - Taxa de desemprego mensal no Brasil;
  - Venda mensal de aparelhos de ar condicionado;
  - Média dos índices diários de CO (monóxido de carbono) em São Paulo.

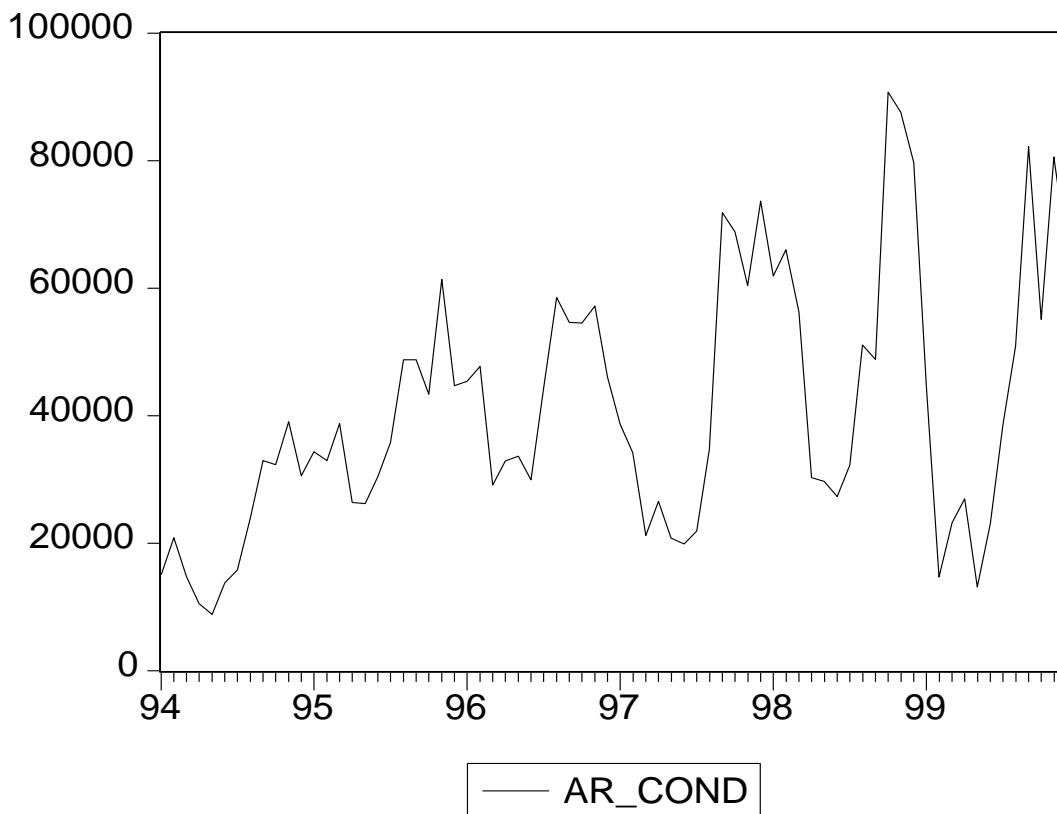
**Exemplo1:** Retornos diários do IBOVESPA (fechamento) no período de 02/01/1995 a 17/05/2002.




**Exemplo 2:** Taxa de desemprego aberto na RMSP (Seade/Dieese/PED, dez/1984 a jun/2005)



**Exemplo 3:** Venda mensal de aparelhos de ar condicionado (indústria, jan/1994 à dez/1999)



**Exemplo 4:** Média dos índices diários de CO (monóxido de carbono) em São Paulo (01/01/91 a 31/12/93; Tolerável = 9 ppm).



**Análise de séries temporais:** é a utilização de ferramentas estatísticas (FAC, periodograma, testes de dependência, testes de raiz unitária, etc) para revelar características importantes da série:

- as observações apresentam autocorrelação ?
  - a série é estacionária ?
  - a série é periódica/possui sazonalidade ?
  - existe dependência não-linear ?
- 
- A partir da análise de séries temporais, é possível obter subsídios para a escolha de um modelo adequado para modelar a série, escolhido dentro de uma classe de modelos pré-existent.
  - Neste curso iremos estudar duas classes de modelos univariados para séries temporais, a saber:

### **1. Modelos ARIMA**

modelos para séries estacionárias/não estacionárias e lineares: AR, MA, ARMA, ARIMA, SARIMA

### **2. Modelos GARCH**

modelos para séries de retornos financeiros utilizados para cálculo de risco de mercado.

- Uma vez construído, um modelo de ST pode ser utilizado para efetuar **previsões probabilísticas** sobre o futuro da série.
- A capacidade de realizar previsões é fundamental no processo de tomada de decisões em diversos contextos e em diversos lugares como órgãos públicos e empresas:
  - Em quanto % devemos aumentar a capacidade instalada da nossa fábrica de televisores digitais ?
  - Qual será a dimensão da nova estação de tratamento de água de Búzios?
  - Em quanto % devemos baixar a taxa de juros básica para que haja um aumento significativo nos empregos oferecidos pela indústria de bicicletas ?
- A formalização dos modelos de séries temporais é realizada a partir do conceito de **processo estocástico**, a ser visto na próxima seção.

## Séries Temporais e Processos Estocásticos

- Um **processo estocástico** é uma função aleatória indexada pelo tempo  $t$ ,  $y_t$ , em que para cada  $t$ , o valor de  $y_t$  é uma variável aleatória.

$$\{y_t : t \in T\}$$

$y_t$  é o estado do processo no instante  $t$ .

- O conjunto  $T$  é o conjunto de índices ou espaço paramétrico do processo estocástico.

### Processos Discretos e Contínuos

- Um processo estocástico  $\{y_t: t \in T\}$  é um **processo contínuo** (ou processo com parâmetro contínuo) se o conjunto  $T$  é um **intervalo, finito ou não, de números reais**.

**Ex:** série da pressão sangüínea para um paciente, monitorada continuamente por um aparelho, no período entre 17 e 18 hs de uma 4ª feira.

- Um processo estocástico  $\{y_t: t \in T\}$  é um **processo discreto** (ou processo com parâmetro discreto) se o conjunto de índices  $T$  é um conjunto **contável**.

**Ex:** série da pressão sangüínea de uma paciente tomada à cada 15 minutos, num período de 1 semana.

## Espaço de Estados

- **Espaço de estados** de um processo estocástico é o conjunto de todos os valores possíveis da variável aleatória  $y_t$ .

pode ser **discreto** ou **contínuo**, se as variáveis aleatórias  $y_t$  forem discretas ou contínuas.

Exs:

1. **Discreto:** número de atendimentos diários no Barra d'Or devido ao consumo excessivo de álcool;
  2. **Contínuo:** temperatura diária, as 21:00 h, no Alto da Boa Vista.
- Os modelos para processos estocásticos são específicos para a combinação entre o tipo de espaço paramétrico (discreto e contínuo) e o tipo do espaço de estado (discreto e contínuo).
  - Neste curso iremos estudar modelos para processos estocásticos com **espaço paramétrico discreto** e **espaço de estado contínuo**.



**Ex:** Série mensal de demanda residencial de energia elétrica na cidade de Rio de Janeiro entre 1990 e 2005.

## **Séries Temporais como realizações de Processos Estocásticos**

- Um processo estocástico é um mecanismo gerador de dados (no tempo e/ou no espaço), cujo **comportamento não pode ser descrito por uma função determinística** no tempo.
- O comportamento futuro de um processo estocástico só pode ser descrito probabilisticamente.
- A estrutura probabilística de um processo estocástico pode ser completamente definida através da especificação da sua distribuição de probabilidade conjunta:

$$F(y_{t_1}, y_{t_2}, \dots, y_{t_T}) = \Pr(y_{t_1} \leq a_1, y_{t_2} \leq a_2, \dots, y_{t_T} \leq a_T)$$

para qualquer subconjunto  $t_i, i=1,2,\dots,T$ .

- A distribuição de probabilidade conjunta geralmente é de difícil especificação.

- Assim sendo, caracterizamos um PE por uma equação estocástica (**modelo**), a partir da qual pode-se obter a evolução de alguns dos seus momentos (como sua média, variância).


**Ex:**

**Processo AR(1)** (ou seja, **auto-regressivo** de 1a ordem)

$$y_t = 0.6 y_{t-1} + e_t \quad e_t \sim \text{NID}(0,1).$$

**estrutura**                      **termo aleatório**

Gráfico no tempo de um processo AR (1)



- No gráfico acima, cada valor de  $y_t$  é uma variável aleatória, e assim sendo, não pode ser completamente determinado a partir dos seus valores passados.
- Nos processos estocásticos, **o futuro é incerto!**
- Os modelos de séries temporais tentam capturar a estrutura de dependência existente no passado da série para, dentre outros objetivos, realizar previsões.
- Assim, o grau de acerto das previsões depende de dois fatores chaves:
  - Que o modelo seja uma boa aproximação da estrutura de dependência da série;

⇒ **testes de especificação**

- Que a estrutura de dependência identificada no passado permaneça razoavelmente estável no futuro.

⇒ **testes de previsão fora da amostra**


- Na prática somente observamos uma única realização de um PE, i.e., uma única ST (inflação, câmbio, etc).

## Processo Estocástico

## Realizações

Processo AR(1)

$$y_t = 0.6y_{t-1} + e_t \quad e_t \sim \text{NID}(0,1),$$



- A partir de uma única realização, a análise de séries temporais procura inferir estatisticamente sobre o processo estocástico subjacente que deu origem à série.
- Para que isso seja possível, é necessário impor algumas hipóteses restritivas sobre o processo estocástico: **estacionariedade e ergodicidade**.

## ***Estacionariedade***

- A noção de estacionariedade está associada à idéia de “equilíbrio estatístico” no tempo: algumas das características probabilísticas do processo permanecem invariantes no tempo.
- Existem diversos dois tipos de estacionariedade:
  - Estacionariedade forte: a característica que permanece invariante no tempo é a **distribuição de probabilidade conjunta** do processo estocástico.

$$F(y_{t_1}, y_{t_2}, \dots, y_{t_T}) = F(y_{t_1+k}, y_{t_2+k}, \dots, y_{t_T+k}) \quad \forall t_1, t_2, \dots, t_T \text{ e } k$$

Esta condição é muito restritiva para processos reais, e assim, na prática, adota-se um tipo de estacionariedade mais branda.

- Estacionariedade Fraca (ou estacionariedade de 2ª ordem): alguns dos **momentos (incondicionais)** do processo estocástico permanecem invariantes ao longo do tempo.

$$i. E[y_t] = \mu \quad \forall t$$

$$ii. E[(y_t - \mu)(y_{t-k} - \mu)] = \gamma_k \quad \forall t,$$

*donde segue que :*

$$E[(y_t - \mu)^2] = \gamma_0 = \sigma_y^2 \quad \forall t$$


- Assim sendo num PE de 2ª ordem:
  - i. a média e a variância (incondicionais) do processo são constantes no tempo;
  - ii. a estrutura de dependência linear  $\gamma_k$  depende apenas da distância entre as observações e neste caso pode-se mostrar que a intensidade da dependência diminui com esta distância.
- Os processos estocásticos são modelos matemáticos úteis, pois oferecem, muitas vezes, uma descrição parcimoniosa das séries reais (econômicas, físicas, biológicas, financeiras etc), as quais podem ser utilizadas para simulação e previsão de uma ST.
- Deve-se, entretanto, estar atentos às simplificações implicadas por estas descrições matemáticas:

*“All models are wrong, but some are useful.”*

**G.E.P. Box**

- As realidades econômicas, físicas, biológicas, que são o verdadeiro “processo” gerador das séries temporais, podem ser extremamente dinâmicas e mutáveis.
- A mudança do processo gerador pressuposto “sob” a série observada é chamada **quebra estrutural**.

**Exemplo clássico de quebra estrutural:** Taxa de câmbio real R\$/US\$.



- Muitas séries reais são não-estacionárias, pois apresentam tendência no tempo.
- Como veremos se uma ST for originalmente não-estacionária temos que torná-la estacionária para que possamos utilizar modelos estacionários.
- Existem dois tipos de tendência:
  - **Tendência Determinística**: o modelo da tendência é uma função determinista do tempo (TS):

Caso particular: considere uma tendência linear sobre um processo  $a_t \sim \text{AR}(1)$ :

$$y_t = \beta_0 + \beta_1 t + a_t,$$

$$a_t = \phi a_{t-1} + \varepsilon_t, \quad |\phi| < 1, \quad \varepsilon_t \sim NID(0, \sigma^2)$$

Segue que:

$$E(y_t) = \beta_0 + \beta_1 t$$

$$\text{Var}(y_t) = \sigma^2 / (1 - \phi^2)$$

$$\rho(y_t, y_{t-k}) = \phi^k$$

- Portanto o processo não satisfaz as condições de estacionariedade de 2ª ordem, e assim é não estacionário.



- Se uma ST tem tendência deste tipo, devemos ajustar o modelo e trabalhar com o resíduo, o qual será, por construção estacionário.

$$\hat{\varepsilon}_t = y_t - [(\hat{\beta}_0 + \hat{\beta}_1 t) + \hat{\phi} a_{t-1}]$$

- **Tendência Estocástica**: o modelo da tendência é uma função estocástica (DS).

- Exemplo canônico de modelo com tendência estocástica

$y_t \sim \text{RW} + \text{drift}$  (passeio aleatório + constante)

$$y_t = a + y_{t-1} + e_t, \quad e_t \sim \text{NID}(0, \sigma^2)$$

$$y_t = at + y_0 + \sum_{i=1}^t e_i$$

- Segue que:

$$E(y_t) = at + y_0$$

$$\text{Var}(y_t) = t \sigma^2$$

$$\rho(k) = [1 - (k / t)]^{1/2}$$

- Os momentos variam explicitamente no tempo, e assim sendo o PE **não é** estacionário de 2ª ordem.
- Se uma ST tem tendência estocástica então para torná-la estacionária basta tomar a 1ª diferença da série

$$z_t = y_t - y_{t-1} = a + e_t,$$

## ***Ergodicidade***

- Ergodicidade na média: a média amostral das observações de uma realização converge para a média do processo:

$$\frac{1}{T} \sum_{t=1}^T y_t \xrightarrow{p} \mu$$

- Ergodicidade de 2a. ordem: a covariância amostral converge para a covariância do processo:

$$\frac{1}{T-k} \sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y}) \xrightarrow{p} \gamma_j$$

- Todo processo ergódico é estacionário, mas nem todo processo estacionário é ergódico.


## Investigando Estacionariedade

- A hipótese de estacionariedade de uma série tem papel fundamental no desenvolvimento da teoria que será apresentada durante o curso, pois a classe dos modelos aqui estudados foi desenvolvida para PE estacionários.
- Dado um PE, utilizando a definição de PE estacionário, podemos saber se este processo é estacionário ou não.
- O que precisamos é de ferramentas estatísticas para investigar a estacionariedade de uma série temporal.
- Esta investigação será realizada através das seguintes ferramentas:
  - gráfico da série no tempo;
  - FAC;
  - Testes de raiz unitária/ não estacionariedade.

## Gráfico da série no tempo

- Em uma **série estacionária**, as observações variam em torno de um valor de equilíbrio, a média (incondicional).

Série de retornos do Ibovespa



**Fato estilizado:** séries de retornos financeiros são em geral estacionárias !

- A maioria das séries econômicas e financeiras que não são estacionárias possuem tendência estocástica.
- Assim sendo para torná-las estacionárias deveremos diferencia-las um número adequado de vezes.

## ***A Função de Autocorrelação (FAC) e a Análise do Correlograma***

- **Função de autocorrelação (FAC)** = representa uma medida de associação linear entre o presente do processo e o seu passado, ou seja, uma medida da “memória” do processo.
- A FAC é o procedimento padrão para investigar a dependência linear implicada por um modelo de ST.
- Em geral, autocorrelação nula para todo  $k$  em um PE não implica que as observações deste processo sejam independentes entre si, podendo existir algum outro tipo de dependência que não seja linear.
- Entretanto, se um PE for independente, a sua FAC, e qualquer outra medida de auto-associação, será nula.

- A função de autocorrelação (FAC) ou correlograma de um determinado PE é obtida através do cálculo da seguinte expressão:

$$\rho_k = \gamma_k / \gamma_0, \quad k = 1, 2, 3, \dots$$

Diagram illustrating the components of the FAC formula:

- $\gamma_k$  is labeled as autocovariância.
- $\gamma_0$  is labeled as variância.
- $k$  is labeled as lags.

- Utilizando a fórmula matemática do processo podemos então para cada  $k$  calcular o numerador

$$\rho_k = \gamma_k / \gamma_0$$

$$\gamma_k = E(y_t y_{t-k}) - E(y_t)E(y_{t-k}), \quad k = 0, 1, 2, \dots$$

- **Propriedades da FAC**

- i.  $\rho_0 = 1$ ;
- ii.  $-1 \leq \rho_k \leq 1$ ;
- ii.  $\rho_k = \rho_{-k}$ , p/  $y_t$  Real.

- **Ex:**  $y_t = a \cos(wt) + b \sin(wt)$ , onde

Onde  $a$  e  $b$  são variáveis aleatórias com  $E(a)=E(b)=0$ ,  $E(ab)=0$ ,  $E(a^2)=E(b^2)=\sigma^2$ .

Segue que:

$$E(y_t)=0, \text{ Var}(y_t)=\sigma^2$$

$$E(y_t y_{t-k}) = \sigma^2 \cos(wk), \text{ utilizando que}$$

$$\cos(a-b) = \cos a \cos b + \sin a \sin b$$

$$\text{Portanto } \rho_k = \cos(wk), \quad k=1,2,3,\dots$$

Assim sendo, o processo é estacionário de 2ª ordem.

- Grosso modo, pode-se dizer que a FAC de um processo estocástico estacionário é uma “assinatura” deste processo. Processos de uma mesma “família” geram FAC’s do mesmo tipo.
- Portanto, a FAC pode ser utilizada como um procedimento para identificar o processo estocástico que gera uma série temporal estacionária.
- Observe que:

- se houver uma relação linear perfeita entre  $y_t$  e  $y_{t-k}$ , então  $|\rho_k| = 1$ ;
- mesmo que  $\rho_k = 0$ , para todo  $k$ , ainda assim pode haver algum outro tipo de relação entre  $y_t$  e  $y_{t-k}$  (relação não-linear).



## Identificando Estacionariedade segundo o correlograma

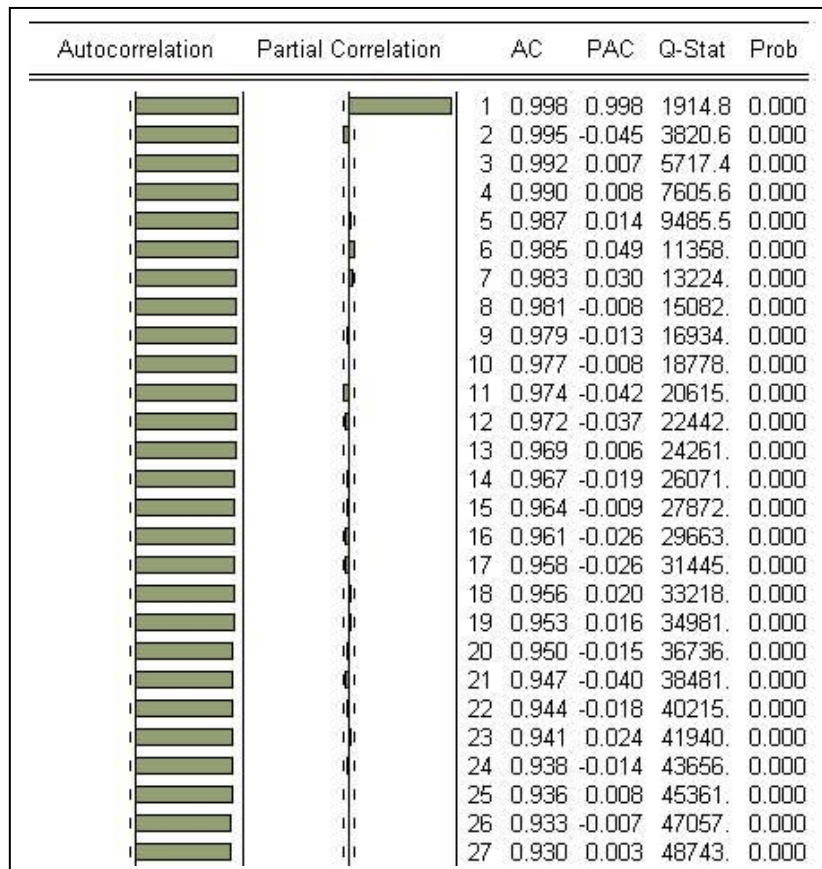
- Para uma **série estacionária**, o correlograma decai rapidamente para zero com o aumento de k, ou é estatisticamente nulo para todo k (ruído branco).

Ex: Correlograma dos **retornos** do Ibovespa.

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	0.045	0.045	3.9799	0.046
		2	-0.006	-0.008	4.0515	0.132
		3	-0.048	-0.047	8.4948	0.037
		4	-0.039	-0.035	11.396	0.022
		5	-0.065	-0.062	19.504	0.002
		6	-0.078	-0.076	31.367	0.000
		7	0.037	0.040	34.049	0.000
		8	0.023	0.012	35.087	0.000
		9	0.035	0.023	37.485	0.000
		10	0.077	0.070	48.865	0.000
		11	0.043	0.033	52.413	0.000
		12	-0.048	-0.048	56.878	0.000
		13	-0.013	0.009	57.190	0.000
		14	-0.021	-0.009	58.013	0.000
		15	0.036	0.047	60.589	0.000
		16	-0.016	-0.010	61.096	0.000
		17	0.000	-0.006	61.096	0.000
		18	-0.003	-0.014	61.111	0.000
		19	0.029	0.029	62.775	0.000
		20	0.033	0.027	64.875	0.000
		21	0.024	0.025	65.989	0.000
		22	-0.013	-0.012	66.300	0.000
		23	0.006	0.015	66.377	0.000
		24	-0.015	-0.013	66.831	0.000
		25	-0.027	-0.023	68.279	0.000
		26	-0.024	-0.020	69.386	0.000
		27	0.009	0.016	69.562	0.000

- Em uma **série não estacionária**, o correlograma decai lentamente para zero com o aumento de k. (Por que ?)

Ex: correlograma da série do **índice Ibovespa**.



## • Testes de raiz unitária

- Grande revolução na Econometria na década de 80!
- As seguintes opções de teste de RU estão disponíveis no EViews ( a partir da versão 4.0):
  - Augmented Dickey Fuller (ADF)
  - Dickey Fuller GLS (DF-GLS)
  - Phillips-Perron (PP)
  - Kwiatkowski-Phillips-Schmidt-Shin (KPSS)
  - Elliot-Rothenberg-Stock point optimal (ERS)
  - Ng-Perron (NP)
- Em todos estes testes a hipótese nula é que a série possui uma raiz unitária (a ST é não-estacionária) e a hipótese alternativa a que a série é estacionária, com exceção do teste KPSS, no qual ocorre o contrário.

Ho: a ST possui uma RU « » a série é não estacionária

Ha: a ST não possui RU « » a série é estacionária

- Existem vários modelos compatíveis com um teste de RU. A equação mais simples possui a forma:

$$Y_t = \phi Y_{t-1} + e_t \quad (I)$$

$H_0: \phi = 1 \rightarrow$  a ST possui uma RU

$H_a: \phi < 1 \rightarrow$  a ST é estacionária

- Como é mais usual testar se o parâmetro é nulo, o teste de RU é efetuado subtraindo-se  $Y_{t-1}$  de ambos os lados da eq. I, resultando em:

$$\Delta Y_t = a_1 Y_{t-1} + e_t \quad (\text{II})$$

$$a_1 = \phi - 1$$

- Portanto nesta nova parametrização o teste será:

$H_0: a_1 = 0 \rightarrow$  a ST possui uma RU


$H_a: a_1 < 0 \rightarrow$  a ST é estacionária

- Um pouco de reflexão indica que existem outras equações compatíveis com RU. Por exemplo, adicionando-se um intercepto  $a_0$  ou um intercepto mais uma tendência determinística,  $a_0 + a_1 t$ , resultam em processos adequados para testar RU.

## Formas do teste de Raiz Unitária

- Como existem várias especificações consistentes com não-estacionariedade ou RU, vão existir várias formas de testar RU.
- A questão importante na prática é escolher a forma do teste de RU adequada para a ST em questão.
- As seguintes formas para teste de RU se apresentam:
  - DF I:  $\Delta Y_t = a_1 Y_{t-1} + e_t, \quad e_t \sim \text{NID}(0, \sigma^2)$   
 $H_0: a_1 = 0 \rightarrow Y_t \sim \text{não-estacionária (RW)}$   
 $H_a: a_1 < 0 \rightarrow Y_t \sim \text{estacionária}$
  - DF II:  $\Delta Y_t = a_0 + a_1 Y_{t-1} + e_t, \quad e_t \sim \text{NID}(0, \sigma^2)$   
 $H_0: a_1 = 0 \rightarrow Y_t \sim \text{RW} + \text{drift}$   
 $H_a: a_1 < 0 \rightarrow Y_t \sim \text{estacionária}$
  - DF III:  $\Delta Y_t = a_0 + a_1 Y_{t-1} + a_2 t + e_t, \quad e_t \sim \text{NID}(0, \sigma^2)$   
 $H_0: a_1 = 0 \rightarrow Y_t \sim \text{RW} + \text{drift em torno de uma tendência determinística.}$   
 $H_a: a_1 < 0 \rightarrow Y_t \sim \text{estacionária (supondo } a_2 = 0)$

- O procedimento prático de testar RU é escolher uma das formas, (i, ii ou iii ) que acomode, simultaneamente, as hipóteses nula e alternativa consistente com a série sendo testada.
- Por exemplo, considere a série de retornos do Ibovespa:



- É óbvio que a série é estacionária com média praticamente nula, e assim sendo a forma adequada para o teste será a I.

## O Teste ADF

- No teste ADF, para corrigir a possível presença de autocorrelação dos resíduos nas equações I, II ou III, é adicionado o seguinte somatório em cada uma destas equações:

$$\sum_{i=1}^P \beta_i \Delta Y_{t-i}$$

transformando-as em ADF-I, ADF-II e ADF-III, respectivamente:

- ADF-I:  $\Delta Y_t = a_1 Y_{t-1} + \sum_{i=1}^P \beta_i \Delta Y_{t-i} + e_t$

- ADF-II:  $\Delta Y_t = a_0 + a_1 Y_{t-1} + \sum_{i=1}^P \beta_i \Delta Y_{t-i} + e_t$

- ADF-III:  $\Delta Y_t = a_0 + a_1 Y_{t-1} + \sum_{i=1}^P \beta_i \Delta Y_{t-i} + a_2 t + e_t$

- A ordem  $p$ , da autoregressão, é geralmente determinada automaticamente por um dos critérios de informação (AIC, BIC etc).
- A estatística de teste para o teste ADF é:

$$t = (\hat{a}_1 - 0) / \text{se}(\hat{a}_1)$$

- Problema: a distribuição desta estatística não é mais a t de Student !
- Possui uma forma não-padrão, obtida por simulação Monte Carlo: Dickey & Fuller (79) e MacKinnon (91).
- Regra de decisão: aceite a Hipótese Nula ao nível de  $\alpha\%$  se:

$$|t| = < \tau_i^{\alpha\%} \quad i=1,2,3 \quad (\text{valores tabelados})$$

- Ou seja, o valor crítico da estatística de teste muda com a forma do teste de RU: I, II ou III.

## Teste PP

- Para o teste PP, utiliza-se uma correção na estatística de teste baseado num ajuste "não paramétrico" na forma desta estatística, o qual corrige, simultaneamente, a presença de heterocedasticidade e autocorrelação nos resíduos.
- Este ajuste necessita da especificação de um parâmetro (*truncation lag*) o qual aparece na determinação da estimativa da variância pela estimativa da densidade espectral na frequência zero.



- As formas das equações permanecem inalteradas, ou seja, não introduzimos o "somatório", como em ADF. Por exemplo, para o modelo II a estatística de teste torna-se:

$$t_{PP} = t_2 \gamma_0^{1/2} / \omega - [ (\omega^2 - \gamma_0) T \text{se}(\hat{a}_1) ] / (2\omega\sigma')$$

$$\omega^2 = \gamma_0 + 2 \sum_{j=1}^q (1 - j/(q+1)) \gamma_j ;$$

$$\gamma_j = (1/T) \sum_{t=j+1}^T \hat{e}_t \hat{e}_{t-j} ;$$

- T é o tamanho da série;
- $\sigma'$  é a estimativa de MQO de  $\sigma$ ;
- q é o *truncation lag*.

- Os valores críticos permanecem o mesmo dos testes ADF-I, ADF-II e ADF-III (assintoticamente).

## • Exemplos dos testes de Raiz Unitária

- IBOVESPA: testado nas estruturas III e II.
- Retornos do IBOVESPA: testado na estrutura I.

	Teste		valores críticos (*)		
	ADF	PP	1%	5%	10%
Ibov	-2.908 (iii)	-2.17	<b>-3.97</b>	<b>-3.41</b>	<b>-3.13</b>
	-1.643 (ii)	-1.66	<b>-3.44</b>	<b>-2.86</b>	<b>-2.57</b>
Ret Ibov	-41.88 (i)	-41.84	<b>-2.57</b>	<b>-1.94</b>	<b>-1.62</b>

\*MacKinnon critical values for rejection of hypothesis of a unit root.

⇒ Conclusão: aceita não-estacionariedade p/ série IBOVESPA e rejeita não-estacionariedade p/ série de retornos do IBOVESPA.

OBS: sabendo-se de antemão que as séries financeiras apresentam heterocedasticidade condicional, o teste de RU mais adequado seria o PP, o qual corrige por heterocedasticidade.

## Modelos ARMA para Séries Temporais Estacionárias

- **Teorema da Decomposição de Wold** = qualquer processo estocástico estacionário  $y_t$  pode ser escrito na forma

$$y_t = m_t + v_t$$

onde:

- $m_t$  e  $v_t$  são processos não-correlacionados;
- $m_t$  é um processo determinístico;
- $v_t$  é definido por

$$v_t = \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i}, \quad \psi_0 = 1, \quad \sum_{i=0}^{\infty} \psi_i^2 < \infty,$$

onde  $\varepsilon_t$  é um ruído branco.

- Ruído branco é um PE estacionário onde as observações são descorrelatadas, ou seja, o processo não possui “memória” (linear).
- É representado usualmente pelo símbolo  $\varepsilon_t$ , e tem uma importância fundamental na construção dos modelos para processos com dependência.

Seus dois primeiros momentos são dados por:

$$E[\varepsilon_t] = 0$$

$$E[\varepsilon_t \varepsilon_{t-k}] = \begin{cases} 0, & k \neq 0 \\ \sigma^2, & k = 0 \end{cases}$$

- Note que se o processo segue a distribuição normal, além de ser descorrelatado ele também será independente (pq?).
- Particularizando o termo determinístico como uma constante (*drift*), temos que:

$$y_t = m + \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i}$$

- Esta é conhecida como a representação linear de um processo estacionário de 2ª ordem.
- Utilizando operador de atraso  $L$  ( $L^k y_t = y_{t-k}$ ), podemos reescrever a representação geral de um PE estacionário como:

$$y_t = m + \Psi(L) \varepsilon_t$$

$$\Psi(L) = \psi_0 + \psi_1 L + \psi_2 L^2 + \dots, \psi_0 = 1$$

- polinômio  $\Psi(L)$ , de grau infinito, poder ser obtido pela razão entre dois polinômios de grau finito, isto é:

$$\Psi(L) = \frac{\Theta_q(L)}{\Phi_p(L)}$$

$$\Theta_q(L) = 1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q$$

$$\Phi_p(L) = 1 - \varphi_1 L - \varphi_2 L^2 - \dots - \varphi_p L^p$$

- Substituindo esta expressão na expressão para  $y_t$ , obtemos:

$$\begin{aligned} y_t &= m + \Psi(L) \varepsilon_t \\ &= m + \frac{\Theta_q(L)}{\Phi_p(L)} \varepsilon_t, \text{ ou} \end{aligned}$$

$$\Phi_p(L) y_t = c + \Theta_q(L) \varepsilon_t$$

em que:

$$- c = (1 - \varphi_1 - \varphi_2 - \dots - \varphi_p) m$$

$$- \Theta_q(L) = 1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q$$

$$- \Phi_p(L) = 1 - \varphi_1 L - \varphi_2 L^2 - \dots - \varphi_p L^p$$

- Utilizando a definição dos operadores de atraso, chegamos à seguinte expressão:

$$y_t = c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

- Os termos  $c, \phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q$  são parâmetros desconhecidos que devem ser estimados a partir dos dados de uma série temporal real.
- Este é denominado um modelo **ARMA(p,q)**, onde:
  - a componente *AR(auto regressivo)*: refere-se aos valores defasados de  $y_t$ .
  - a componente *MA (moving average)* refere-se aos valores presente e defasados do ruído branco.
- O nosso estudo será iniciado pela investigação das propriedades estatísticas dos modelos AR puro, em seguida MA puro e por fim os modelos mistos ARMA.

## ***Modos condicional e Incondicional de uma série temporal estacionária***

- Inicialmente, é importante distinguir entre os modos condicional e incondicional de um modelo para ST.
- Um mesmo modelo de ST apresenta um modo condicional e um modo incondicional.
- O **modo condicional** explora a dependência existente na série, sendo utilizado para:
  - previsão de curto prazo;
  - estimação dos parâmetros do modelo;
  - diagnósticos do modelo;
- Por sua vez, o **modo incondicional** é utilizado para:
  - checar se a distribuição implicada pelo modelo é adequada para os dados (a série temporal);
  - checar se a FAC implicada pelo modelo tem a mesma forma do correlograma obtido a partir dos dados;
  - estabelecer as condições de estacionariedade do modelo, em termos de restrições nos seus parâmetros;
  - obter a previsão de longo prazo para a série, a partir do modelo.

## **Processos AR (autoregressivos)**

### **Processo AR(1)**

- Considere o processo AR (1)

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t$$

em que  $\varepsilon_t$  é um ruído branco Gaussiano  $N(0, \sigma^2)$ .

- Obtendo os seus momentos de acordo com o modo **condicional**, tem-se:

- $E(y_t | \mathbf{Y}_{t-1}) = c + \phi_1 y_{t-1}$
- $\text{Var}(y_t | \mathbf{Y}_{t-1}) = \sigma^2$
- $f(y_t | \mathbf{Y}_{t-1}) \sim N(c + \phi_1 y_{t-1}, \sigma^2)$

- Um processo AR(1), na sua forma incondicional, é, do ponto de vista matemático, uma equação de diferenças de 1ª ordem, não homogênea.
- A solução desta equação pode ser obtida através de dois modos distintos:
  - i. por iteração da equação;
  - ii. pela solução formal da equação de diferença



i. Por iteração da equação:

$$y_1 = c + \varphi_1 y_0 + \varepsilon_1$$

$$y_2 = c + \varphi_1 y_1 + \varepsilon_2 = c + \varphi_1 (c + \varphi_1 y_0 + \varepsilon_1) + \varepsilon_2$$

$$y_t = c \sum_{i=0}^{t-1} \varphi_1^i + \varphi_1^t y_0 + \sum_{i=0}^{t-1} \varphi_1^i \varepsilon_{t-i}$$

$$\begin{aligned} E(y_t) &= c \sum_{i=0}^{t-1} \varphi_1^i + \varphi_1^t E(y_0) + \sum_{i=0}^{t-1} \varphi_1^i E(\varepsilon_{t-i}) \\ &= c (1 - \varphi_1^t) / (1 - \varphi_1) + \varphi_1^t y_0 \end{aligned}$$

$$E(y_t) = c / (1 - \varphi_1), \text{ se } |\varphi_1| < 1, t \rightarrow \infty.$$

$$\begin{aligned} \text{Var}(y_t) &= E(y_t - E(y_t))^2 = E\left(\sum_{i=0}^{t-1} \varphi_1^i \varepsilon_{t-i}\right)^2 \\ &= E\left(\sum_{i=0}^{t-1} \varphi_1^{2i} \varepsilon_{t-i}^2 + 2 \sum_{i < j}^{t-1} \varphi_1^i \varphi_1^j \varepsilon_{t-i} \varepsilon_{t-j}\right) \\ &= \sigma^2 \sum_{i=0}^{t-1} \varphi_1^{2i} = \sigma^2 (1 - \varphi_1^{2t}) / (1 - \varphi_1^2) \end{aligned}$$

$$\text{Var}(y_t) = \sigma^2 / (1 - \varphi_1^2), \text{ se } |\varphi_1| < 1, t \rightarrow \infty$$

- Tem-se, portanto, que a **distribuição incondicional de  $y_t$**  é **combinação linear** de v.a's **normais**, e assim sendo também será normal com:

$$f(y_t) \sim N(c / (1 - \phi), \frac{\sigma^2}{1 - \phi_1^2})$$

ii. Por solução formal da equação: a solução desta equação é dada pela soma da solução homogênea ( $y_t^h$ ) mais a solução particular ( $y_t^p$ ):

$$y_t = y_t^h + y_t^p$$

- a solução homogênea  $y_t^h$  é obtida fazendo todos os termos que não envolvem  $y_t$  igual a zero e achando a raiz do polinômio em  $z$ ,  $z=1/L$ .

$$y_t = \phi_1 y_{t-1}$$

$$(1 - \phi_1 L) y_t = 0$$

$$(1 - \phi_1 L) = 0 \therefore z = 1/L = \phi_1$$

Observar que  $y_t^h = A \phi_1^t$  é solução

- a solução particular é obtida a equação em termos do operador de atraso ( $L$ ):

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t$$

$$(1 - \phi_1 L) y_t = c + \varepsilon_t$$

$$y_t^p = (1 - \phi_1 L)^{-1} c + (1 - \phi_1 L)^{-1} \varepsilon_t$$

- Portanto a solução geral da equação será dada por:

$$y_t = y_t^h + y_t^p$$

$$y_t = A\varphi_1^t + (1 - \varphi_1 L)^{-1} c + (1 - \varphi_1 L)^{-1} \varepsilon_t$$

- Assumindo que  $|\varphi_1| < 1$  e que  $t \rightarrow \infty$  (o que deduziremos como condições suficientes para que um processo AR(1) seja assintoticamente estacionário), tem-se que:

$$y_t = \sum_{j=0}^{\infty} \varphi_1^j L^j c + \sum_{j=0}^{\infty} \varphi_1^j L^j \varepsilon_t$$

$$y_t = c / (1 - \varphi_1) + \sum_{j=0}^{\infty} \varphi_1^j \varepsilon_{t-j}$$

- Nestas condições obtemos os mesmos resultados da solução por iteração para a média, variância e autocovariância.
- Observe que a partir da última expressão derivada para  $y_t$ , **um processo AR (1) pode ser reescrito como um processo MA( $\infty$ )**. Este é um resultado geral para processos auto-regressivos e que será explorado mais adiante.

## A função de autocorrelação para um processo AR (1)

- A FAC é a “assinatura” de um PE, e deve ser sempre calculada, pois será utilizada para identificar o melhor modelo para uma dada série temporal.

$$\begin{aligned}\rho(k) &= E[(y_t - \mu)(y_{t-k} - \mu)] / \text{Var}(y_t), \quad k = 1, 2, 3, \dots \\ &= \gamma(k) / \gamma(0), \quad \gamma(0) = \text{Var}(y_t).\end{aligned}$$

- Para calcularmos esta expressão, tomamos a equação do processo AR (1), utilizando que  $c = \mu(1 - \phi_1)$ , chegando à:

$$y_t - \mu = \phi_1(y_{t-1} - \mu) + \varepsilon_t$$

- Multiplicando ambos os lados da equação por  $(y_{t-k} - \mu)$ , tem-se:

$$(y_t - \mu)(y_{t-k} - \mu) = \phi_1(y_{t-1} - \mu)(y_{t-k} - \mu) + \varepsilon_t(y_{t-k} - \mu)$$

- Tomando a esperança dos dois lados da equação e utilizando que  $E[\varepsilon_t(y_{t-k} - \mu)] = 0$ , chega-se à:

$$E[(y_t - \mu)(y_{t-k} - \mu)] = \phi_1 E[(y_{t-1} - \mu)(y_{t-k} - \mu)]$$

- A hipótese de estacionariedade para o processo implica que:

$$E[(y_{t-1} - \mu)(y_{t-k} - \mu)] = E[(y_t - \mu)(y_{t-k-1} - \mu)] = \gamma_{k-1}$$

- Assim, chegamos a seguinte expressão para  $E[(y_t - \mu)(y_{t-k} - \mu)] = \gamma_k$ :

$$\gamma_k = \Phi_1 \gamma_{k-1}$$

- Por substituição recursiva, deduzimos a expressão desejada:

$$\gamma_k = \Phi_1^k \gamma_0$$

- A função de autocorrelação é dada por:

$$\rho(k) = \gamma_k / \gamma_0 = \Phi_1^k, k = 1, 2, 3...$$

- senóide amortecida                      se  $-1 < \phi_1 < 0$ ;
- exponencial amortecida                se  $0 < \phi_1 < 1$ .

## Previsão para o processo AR (1)

- Previsões para valores da série  $k$ -passos à frente, a partir do instante  $t$ , podem ser obtidas pela projeção do modelo no futuro. A variável  $k$  é chamada **horizonte de previsão**.
- A função de previsão  $k$ -passos à frente, é por definição, a média do processo projetada  $k$  passos à frente, condicional nas observações até o tempo  $t$ . Formalmente:

$$\hat{y}_{t+k|t} = E(y_{t+k} | \mathbf{Y}_t)$$

- O erro quadrático médio desta previsão (MSE), também pode ser obtido utilizando que:

$$\text{MSE}(\hat{y}_{t+k|t}) = \mathbb{E}[(y_{t+k} - \hat{y}_{t+k|t})^2 | \mathbf{Y}_t]$$

- Finalmente, intervalos de confiança de  $(1-\alpha)\%$  para a previsão podem ser obtidos, utilizando que

$$\hat{y}_{t+k|t} \pm z^{\alpha/2} \sqrt{\text{MSE}(\hat{y}_{t+k|t})}$$

- O cálculo de  $\text{MSE}(\hat{y}_{t+k|t})$  pode ser feita através de substituição recursiva da expressão do processo:

$$y_t = c + \varphi_1 y_{t-1} + \varepsilon_t \Rightarrow y_{t+1} = c + \varphi_1 y_t + \varepsilon_{t+1}$$

$$\begin{aligned} y_{t+2} &= c + \varphi_1 y_{t+1} + \varepsilon_{t+2} = c + \varphi_1 (c + \varphi_1 y_t + \varepsilon_{t+1}) + \varepsilon_{t+2} \\ &= c (1 + \varphi_1) + \varphi_1^2 y_t + (\varphi_1 \varepsilon_{t+1} + \varepsilon_{t+2}) \end{aligned}$$

$$y_{t+k} = c \sum_{i=1}^k \varphi_1^{k-i} + \varphi_1^k y_t + \sum_{i=1}^k \varphi_1^{k-i} \varepsilon_{t+i}$$

$$\hat{y}_{t+k|t} = E(y_{t+k} | Y_t) = c \frac{(1 - \varphi_1^k)}{1 - \varphi_1} + \varphi_1^k y_t$$

- Observe que  $\lim_{k \rightarrow \infty} \hat{y}_{t+k|t} = c / (1 - \varphi_1)$ , a média incondicional.
- Finalmente:

$$\begin{aligned}\text{MSE}(\hat{y}_{t+k|t}) &= \text{E}[(y_{t+k} - \hat{y}_{t+k|t})^2 | \mathbf{Y}_t] = \sum_{i=1}^k \varphi_1^{2(k-i)} \text{E}(\varepsilon_{t+i}^2 | \mathbf{Y}_t) \\ &= \sigma^2 \sum_{i=1}^k \varphi_1^{2(k-i)}\end{aligned}$$

$$\text{MSE}(\hat{y}_{t+k|t}) = \sigma^2 (1 + \varphi_1^2 + \varphi_1^4 + \varphi_1^6 + \dots + \varphi_1^{2(k-1)})$$



## Processo AR(2)

- Considere o processo AR(2)

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- No **modo condicional**:

- $E(y_t | \mathbf{Y}_{t-1}) = c + \phi_1 y_{t-1} + \phi_2 y_{t-2}$
- $\text{Var}(y_t | \mathbf{Y}_{t-1}) = \sigma^2$
- $f(y_t | \mathbf{Y}_{t-1}) \sim N(c + \phi_1 y_{t-1} + \phi_2 y_{t-2}, \sigma^2)$

- Quanto ao **modo incondicional**, viu-se que ele estabelece as condições de estacionariedade de um modelo.
- Uma das maneiras de se obter a forma incondicional é através da substituição recursiva. Entretanto, apenas p/ modelos AR(1) este procedimento é recomendável, a não ser que re-escrevamos o modelo AR(p) em forma vetorial.
- Para modelos AR(p),  $p > 1$ , utiliza-se a **decomposição do polinômio**  $\Phi_p(L)$ .

- A “analogia direta” seria dizer que as condições de estacionariedade de um processo AR(2) seriam  $|\phi_i| < 1$ ,  $i=1,2$ . Mas isto não está correto!
- Como será visto adiante, as verdadeiras condições de estacionariedade de um processo AR(2) são dadas por:

$$\begin{aligned}\phi_2 + \phi_1 &< 1 \\ \phi_2 - \phi_1 &< 1 \\ -1 < \phi_2 < 1 &\quad (\text{ou } |\phi_2| < 1)\end{aligned}$$

- A investigação das condições de estacionariedade de um processo AR(2) é efetuada a partir da solução da equação de diferenças implicada pelo processo.
- Com vimos, a solução desta equação é dada pela soma da solução homogênea ( $y_t^h$ ) mais a solução particular ( $y_t^p$ ):

$$y_t = y_t^h + y_t^p$$

- Para construirmos estas soluções devemos, primeiro, obter a decomposição do polinômio  $\Phi_2(L) = (1 - \phi_1 L - \phi_2 L^2)$ .
- A partir desta decomposição podemos construir as soluções da equação do AR(2), cujo forma irá depender da natureza das raízes  $\lambda$ 's:

- 1) reais e diferentes
- 2) reais e iguais
- 3) complexas conjugadas

**1) Raízes Reais com  $\lambda_1 \neq \lambda_2$  :**

$$y_t = c + \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \varepsilon_t$$

$$(1 - \varphi_1 L - \varphi_2 L^2) y_t = c + \varepsilon_t$$

Mas

$$(1 - \varphi_1 L - \varphi_2 L^2) = (1 - \lambda_1 L)(1 - \lambda_2 L) \quad (I)$$

onde os  $\lambda$ 's são raízes do polinômio

$$f(z) = z^2 - \varphi_1 z - \varphi_2, \quad z = 1/L$$

De (I), segue que:

- a)  $\lambda_1 \lambda_2 = -\varphi_2$
- b)  $\lambda_1 + \lambda_2 = \varphi_1$

**Solução da equação homogênea:**

$$y_t^h = A_1 \lambda_1^t + A_2 \lambda_2^t$$

em que  $A_1$  e  $A_2$  são constantes determinadas pelas condições iniciais e  $\lambda_1$  e  $\lambda_2$  são as raízes do polinômio em  $z$ ,  $z = 1/L$ .

### Solução da equação particular:

$$\begin{aligned} y_t^p &= \frac{1}{(1-\lambda_1 L)(1-\lambda_2 L)} (c + \varepsilon_t) \\ &= \frac{1}{(\lambda_1 - \lambda_2)} \left[ \frac{\lambda_1}{(1-\lambda_1 L)} - \frac{\lambda_2}{(1-\lambda_2 L)} \right] (c + \varepsilon_t) \end{aligned}$$

### Solução geral:

$$y_t = y_t^h + y_t^p$$

$$y_t = A_1 \lambda_1^t + A_2 \lambda_2^t + \frac{1}{(\lambda_1 - \lambda_2)} \left[ \frac{\lambda_1}{(1-\lambda_1 L)} - \frac{\lambda_2}{(1-\lambda_2 L)} \right] (c + \varepsilon_t)$$

- Note que, sem impormos restrições ao processo, este é não estacionário, pois  $E(y_t)$  depende explicitamente do tempo.
- Entretanto, usando que:
  - $|\lambda_i| < 1, i = 1, 2$  (supomos esta condição);

- o tempo  $t$  está suficientemente afastado da origem;
- $\frac{1}{(1-\lambda_i L)} = \sum_{j=0}^{\infty} (\lambda_i L)^j$ , se  $|\lambda_i| < 1$ ,  $i = 1, 2$ .

segue que:

$$\begin{aligned}
 y_t &= \frac{1}{(\lambda_1 - \lambda_2)} \left\{ \left[ \lambda_1 \sum_{j=0}^{\infty} \lambda_1^j L^j - \lambda_2 \sum_{j=0}^{\infty} \lambda_2^j L^j \right] (c + \varepsilon_t) \right\} \\
 &= \frac{1}{(\lambda_1 - \lambda_2)} \left[ \sum_{j=0}^{\infty} \lambda_1^{j+1} \varepsilon_{t-j} - \sum_{j=0}^{\infty} \lambda_2^{j+1} \varepsilon_{t-j} \right] + c \sum_{j=0}^{\infty} \lambda_1^{j+1} - c \sum_{j=0}^{\infty} \lambda_2^{j+1} \\
 &= \frac{1}{(\lambda_1 - \lambda_2)} \left\{ \left[ \frac{\lambda_1}{(1-\lambda_1)} - \frac{\lambda_2}{(1-\lambda_2)} \right] c + \sum_{j=0}^{\infty} (\lambda_1^{j+1} - \lambda_2^{j+1}) \varepsilon_{t-j} \right\} \\
 &= \left[ \frac{1}{(1-\lambda_1)(1-\lambda_2)} \right] c + \sum_{j=0}^{\infty} \frac{(\lambda_1^{j+1} - \lambda_2^{j+1})}{(\lambda_1 - \lambda_2)} \varepsilon_{t-j}
 \end{aligned}$$

- Assim, o processo pode ser escrito como:

$$y_t = m + \sum_{j=0}^{\infty} k_j \varepsilon_{t-j}$$

em que

$$m = \frac{c}{(1-\lambda_1)(1-\lambda_2)} = \frac{c}{(1-\varphi_1-\varphi_2)}$$

onde utilizamos a relação entre os  $\lambda$ 's e os  $\varphi$ 's dada pelas eqs (a) e (b).

$$k_j = \frac{(\lambda_1^{j+1} - \lambda_2^{j+1})}{(\lambda_1 - \lambda_2)}$$

- A partir desta expressão final, podemos, em princípio calcular a média e variância incondicionais e observar que ambas independem do tempo.
- Utilizando que  $\varepsilon_{t-j}, j = 0 \dots n$  é um ruído branco, tem-se que:

$$E(y_t) = m = \frac{c}{(1 - \varphi_1 - \varphi_2)}$$

- A variância incondicional pode ser calculada como a seguir (o termo cruzado desaparece usando que  $E(\varepsilon_t \varepsilon_s) = 0, t \neq s$ ).

$$\begin{aligned} Var(y_t) &= E(y_t - m)^2 \\ &= \sum_{j=0}^{\infty} k_j^2 E(\varepsilon_{t-j}^2) \\ &= \sigma^2 \sum_{j=0}^{\infty} k_j^2 \end{aligned}$$

- A avaliação deste somatório nos levará a uma expressão complicada em termo dos  $\lambda$ 's, a qual poderia ser reparametrizada em termo dos  $\varphi$ 's, utilizando as eqs (a) e (b).

- Entretanto uma melhor estratégia para se chegar a expressão da variância será utilizar a eq. original:

$$y_t = c + \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \varepsilon_t$$

$$\text{Usando que a média } m = \frac{c}{(1 - \varphi_1 - \varphi_2)} \rightarrow c = m(1 - \varphi_1 - \varphi_2).$$

Assim sendo:

$$(y_t - m) = \varphi_1 (y_{t-1} - m) + \varphi_2 (y_{t-2} - m) + \varepsilon_t \quad (I)$$

$$\begin{aligned} \text{Var}(y_t) = E[(y_t - m)^2] &= \varphi_1 E[(y_{t-1} - m)(y_t - m)] + \\ &+ \varphi_2 E[(y_{t-2} - m)(y_t - m)] + E[(y_t - m) \varepsilon_t] \end{aligned}$$

$$\gamma(0) = \varphi_1 \gamma(1) + \varphi_2 \gamma(2) + \sigma^2 \quad (II)$$

Precisamos das expressões para  $\gamma(1)$  e  $\gamma(2)$ , as quais são obtidas multiplicando a eq.(I) por  $E(y_{t-1} - m)$  e  $E(y_{t-2} - m)$ , respectivamente:

$$\gamma(1) = \varphi_1 \gamma(0) + \varphi_2 \gamma(1) \rightarrow \gamma(1) = \frac{\varphi_1 \gamma(0)}{(1 - \varphi_2)}$$

$$\gamma(2) = \varphi_1 \gamma(1) + \varphi_2 \gamma(0) \rightarrow \gamma(2) = \frac{\gamma(0)(\varphi_1^2 - \varphi_2^2 + \varphi_2)}{(1 - \varphi_2)}$$

Finalmente, substituindo estas expressões na expressão (II), após alguma álgebra obtemos:

$$\text{Var}(y_t) = \frac{(1 - \varphi_2) \sigma^2}{(1 + \varphi_2)((1 - \varphi_2)^2 - \varphi_1^2)}$$

- É fácil de ver então que para que a variância incondicional do processo AR(2) esteja bem definida, i.e., seja positiva e não nula, é necessário impormos as seguintes restrições nos parâmetros do processo:

$$\varphi_2 + \varphi_1 < 1, \quad \varphi_2 - \varphi_1 < 1, \quad |\varphi_2| < 1$$

que são as condições de estacionariedade de um processo AR(2).

**2) Raízes Reais com  $\lambda_1 = \lambda_2 = \lambda$  :**

$$\begin{aligned} y_t &= c + \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \varepsilon_t \\ (1 - \varphi_1 L - \varphi_2 L^2) y_t &= c + \varepsilon_t \\ (1 - \lambda L)^2 y_t &= c + \varepsilon_t \end{aligned}$$

**Solução da equação homogênea**

$$y_t^h = A_1 \lambda^t + A_2 t \lambda^t$$

em que  $A_1$  e  $A_2$  são constantes determinadas pelas condições iniciais (prove que esta solução satisfaz a eq. homogênea).



### Solução da equação particular:

$$y_t^p = \frac{1}{(1-\lambda L)^2} (c + \varepsilon_t)$$

### Solução geral:

$$y_t = A_1 \lambda^t + A_2 t \lambda^t + \frac{1}{(1-\lambda L)^2} (c + \varepsilon_t)$$

- Novamente, note que o processo não é estacionário, pois  $E(y_t)$  depende explicitamente do tempo.
- De forma análoga à condição anterior, utilizando que:

$$|\lambda_i| < 1, i = 1, 2$$

$$\frac{1}{(1-\lambda_i L)} = \sum_{j=0}^{\infty} (\lambda_i L)^j, \text{ se } |\lambda_i| < 1, i = 1, 2, t \rightarrow \infty$$

(para provar que  $\lim_{t \rightarrow \infty} t \lambda^t = 0$  utilize que  $\lim_{t \rightarrow \infty} t \lambda^t = \lim_{t \rightarrow \infty} (\lambda^t + \lambda^t + \dots + \lambda^t) = \lim_{t \rightarrow \infty} (0 + 0 + 0 \dots) = 0$ )

Sob essas condições segue que:

$$\begin{aligned}
y_t &= \frac{1}{(1-\lambda L)} \left[ \frac{1}{(1-\lambda L)} (c + \varepsilon_t) \right] \\
&= \frac{1}{(1-\lambda L)} \left[ \frac{c}{(1-\lambda L)} + \sum_{j=0}^{\infty} \lambda^j \varepsilon_{t-j} \right] \\
&= \frac{c}{(1-\lambda L)^2} + \sum_{j=0}^{\infty} \lambda^j \frac{1}{(1-\lambda L)} \varepsilon_{t-j}, \\
&= \frac{c}{(1-\lambda)^2} + \sum_{j=0}^{\infty} (j+1) \lambda^j \varepsilon_{t-j}
\end{aligned}$$

- De modo semelhante ao caso das raízes distintas, o processo pode ser escrito de outra forma:

$$y_t = m + \sum_{j=0}^{\infty} k_j \varepsilon_{t-j}$$

em que

$$m = \frac{c}{(1-\lambda)^2}$$

$$k_j = (j+1) \lambda^j$$

- A partir desta expressão final, poderíamos calcular a média e variância incondicionais, mas como no caso anterior, é mais indicado utilizar a eq. original (em termo dos  $\varphi$ 's) para este propósito.

- É claro que as expressões da média e variância serão dadas pelas mesmas expressões previamente calculadas, i.e.:

$$E(y_t) = \frac{c}{(1 - \varphi_1 - \varphi_2)}$$

$$\text{Var}(y_t) = \frac{(1 - \varphi_2) \sigma^2}{(1 + \varphi_2)(1 - \varphi_1 - \varphi_2)(1 - \varphi_1 + \varphi_2)}$$

### 3) Raízes Complexas Conjugadas:

$$y_t = c + \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \varepsilon_t$$

$$(1 - \varphi_1 L - \varphi_2 L^2) y_t = c + \varepsilon_t$$

$$(1 - \lambda_1 L)(1 - \lambda_2 L) y_t = c + \varepsilon_t$$

#### ▪ Solução da equação homogênea:

- Apesar de complexas, as raízes da equação homogênea são distintas, e a solução segue a forma do primeiro caso:

$$y_t^h = A_1 \lambda_1^t + A_2 \lambda_2^t$$

em que  $A_1$  e  $A_2$  também são constantes (complexas) determinadas pelas condições iniciais.

- Se tivermos  $\Delta = \varphi_1^2 + 4\varphi_2 < 0$ , os  $\lambda$ 's serão complexos conjugados com  $\lambda_j = a \pm bi$ ,  $j=1,2$  em que:

$$\begin{aligned}\lambda_1 + \lambda_2 &= \varphi_1 \rightarrow a = \varphi_1/2 \\ \lambda_1 - \lambda_2 &= i\sqrt{-\Delta} \rightarrow b = \sqrt{-\Delta}/2\end{aligned}$$

- Podemos reescrever as raízes usando coordenadas polares de modo que  $\lambda_j = R e^{\pm i\theta}$  em que  $R^2 = a^2 + b^2 = -\varphi_2$  e assim segue que  $|\lambda_j| = R = \sqrt{-\varphi_2}$ ,  $j=1,2$
- Reescrevendo a solução homogênea da equação de diferenças do processo em termos da representação em coordenadas polares das raízes, tem-se:

$$y_t^h = A_1 R^t e^{i\theta t} + A_2 R^t e^{-i\theta t}$$

- Como  $y_t^h$  é um número real,  $A_1$  e  $A_2$  devem ser números complexos. Apesar de serem números complexos arbitrários, demonstra-se que  $A_1$  e  $A_2$  devem possuir a seguinte forma:

$$A_1 = B_1 e^{iB_2} \quad \text{e} \quad A_2 = B_1 e^{-iB_2}$$

- Após as devidas substituições, podemos finalmente escrever  $y_t^h$  como:

$$y_t^h = R^t 2B_1 \cos(\theta t + B_2) = C R^t \cos(\theta t + B_2), \quad C = 2B_1$$

- Assim para que  $\lim_{t \rightarrow \infty} y_t^h = 0$ , de forma que o processo seja estacionário, é necessário e suficiente que imponhamos a condição  $|\lambda_j| = R = \sqrt{-\phi_2} < 1$ .

▪ **Solução da equação particular:**

$$\begin{aligned} y_t^p &= \frac{1}{(1-\lambda_1 L)(1-\lambda_2 L)} (c + \varepsilon_t) \\ &= \frac{1}{(\lambda_1 - \lambda_2)} \left[ \frac{\lambda_1}{(1-\lambda_1 L)} - \frac{\lambda_2}{(1-\lambda_2 L)} \right] (c + \varepsilon_t) \end{aligned}$$

▪ **Solução geral:**

$$y_t = R^t B_1 \cos(\theta t + B_2) + \frac{1}{(\lambda_1 - \lambda_2)} \left[ \frac{\lambda_1}{(1-\lambda_1 L)} - \frac{\lambda_2}{(1-\lambda_2 L)} \right] (c + \varepsilon_t)$$

- Note que o processo não é estacionário, pois  $E(y_t)$  depende explicitamente do tempo.

- Nota-se também que a condição de estacionariedade está diretamente ligada ao valor de  $R$ . De fato, o processo será assintoticamente estacionário se:

$$R = \sqrt{-\phi_2} < 1$$

- Utilizando ainda que:

$$\frac{1}{(1 - \lambda_i L)} = \sum_{j=0}^{\infty} (\lambda_i L)^j, \text{ se } |\lambda_i| < 1, i = 1, 2$$

$$t \rightarrow \infty$$

segue que:

$$\begin{aligned} y_t &= \frac{1}{(\lambda_1 - \lambda_2)} \left\{ \left[ \lambda_1 \sum_{j=0}^{\infty} \lambda_1^j L^j - \lambda_2 \sum_{j=0}^{\infty} \lambda_2^j L^j \right] (c + \varepsilon_t) \right\} \\ &= \frac{1}{(\lambda_1 - \lambda_2)} \left[ \sum_{j=0}^{\infty} \lambda_1^{j+1} \varepsilon_{t-j} - \sum_{j=0}^{\infty} \lambda_2^{j+1} \varepsilon_{t-j} \right] + c \sum_{j=0}^{\infty} \lambda_1^{j+1} - c \sum_{j=0}^{\infty} \lambda_2^{j+1} \\ &= \frac{1}{(\lambda_1 - \lambda_2)} \left\{ \left[ \frac{\lambda_1}{(1 - \lambda_1)} - \frac{\lambda_2}{(1 - \lambda_2)} \right] c + \sum_{j=0}^{\infty} (\lambda_1^{j+1} - \lambda_2^{j+1}) \varepsilon_{t-j} \right\} \\ &= \left[ \frac{1}{(1 - \lambda_1)(1 - \lambda_2)} \right] c + \sum_{j=0}^{\infty} \frac{(\lambda_1^{j+1} - \lambda_2^{j+1})}{(\lambda_1 - \lambda_2)} \varepsilon_{t-j} \end{aligned}$$

- Assim, o processo pode ser escrito como:

$$y_t = m + \sum_{j=0}^{\infty} k_j \varepsilon_{t-j}$$

em que:

$$m = \frac{c}{(1-\lambda_1)(1-\lambda_2)} = \frac{c}{(1-\varphi_1-\varphi_2)}$$

$$k_j = \frac{(\lambda_1^{j+1} - \lambda_2^{j+1})}{(\lambda_1 - \lambda_2)}$$

- Observe que mesmo os  $\lambda$ 's sendo números complexos, tanto  $m$  quanto  $k_j$  serão reais. Pode-se facilmente provar que:

$$(1-\lambda_1)(1-\lambda_2) = (1-\text{Re}^{i\theta})(1-\text{Re}^{-i\theta}) = 1 - 2R\cos(\theta) + R^2$$

$$k_j = \frac{(\lambda_1^{j+1} - \lambda_2^{j+1})}{(\lambda_1 - \lambda_2)} = \frac{R^{j+1}e^{i\theta(j+1)} - R^{j+1}e^{-i\theta(j+1)}}{R e^{i\theta} - R e^{-i\theta}} = \frac{R^j \sin(\theta(j+1))}{\sin(\theta)}$$

- A partir desta expressão final, poderíamos, em princípio, calcular a média e variância incondicionais, mas como no caso anterior, é mais indicado utilizar a eq. original (em termo dos  $\varphi$ 's) para este propósito.
- É claro que as expressões da média e variância serão dadas pelas mesmas expressões previamente calculadas, i.e.:

$$E(y_t) = \frac{c}{(1 - \varphi_1 - \varphi_2)}$$

$$\text{Var}(y_t) = \frac{(1 - \varphi_2) \sigma^2}{(1 + \varphi_2)(1 - \varphi_1 - \varphi_2)(1 - \varphi_1 + \varphi_2)}$$

## Forma da FAC para um processo AR (2)

- De forma análoga à derivação da expressão para a função de autocorrelação para um processo AR(1) (pg. 41), chega-se a uma expressão para a auto-correlação de ordem  $k$  de um processo AR(2):

$$(y_t - m) = \varphi_1 (y_{t-1} - m) + \varphi_2 (y_{t-2} - m) + \varepsilon_t$$

$$E[(y_t - m)(y_{t-k} - m)] = \varphi_1 E[(y_{t-1} - m)(y_{t-k} - m)] + \varphi_2 E[(y_{t-2} - m)(y_{t-k} - m)] + E[(y_{t-k} - m) \varepsilon_t]$$

$$\gamma(k) = \varphi_1 \gamma(k-1) + \varphi_2 \gamma(k-2)$$

$$\rho(k) = \varphi_1 \rho(k-1) + \varphi_2 \rho(k-2), \quad k = 1, 2, \dots$$

- Nota-se que a FAC para um processo AR(2) segue uma equação de diferenças de 2ª ordem, homogênea.
- Observe a solução da equação acima, que descreve a FAC para o processo AR(2), é **idêntica** a solução da equação homogênea do processo AR(2) a qual nos dedicamos na seção anterior.



$$(1 - \varphi_1 L - \varphi_2 L^2) \rho(k) = 0$$

- Analisando as 3 possibilidades para as raízes do polinômio  $\Phi_2(L) = (1 - \varphi_1 L - \varphi_2 L^2)$  detalhadas na seção anterior, é interessante observar que:
  - nos casos de raízes reais ( diferentes ou idênticas), a FAC do AR(2) terá um padrão semelhante à de um AR(1), como amortecimento exponencial.
  - no caso de raízes complexas o AR(2) apresenta um comportamento de senóide amortecida.

## Condições de estacionariedade para modelos auto-regressivos

- Para o processo AR (2), observa-se que o estabelecimento das condições de estacionariedade são verificadas nas raízes do polinômio  $f(z) = \Phi_2(z)$ ,  $z = 1/L$ , e não diretamente nos parâmetros originais do modelo.
- A questão que se coloca agora é como expressar as restrições de estacionariedade em termo dos parâmetros originais do modelo,  $\varphi_1$  e  $\varphi_2$ ?
- A chave para esta resposta está nas relações entre os  $\varphi$ 's e os  $\lambda$ 's, as quais são dadas pela solução das raízes do polinômio  $\Phi_2(L)$ .
- Como já visto, a partir de  $(1 - \varphi_1 L - \varphi_2 L^2) = 0$ , fazendo  $z = 1/L$ , chegamos à  $(z^2 - \varphi_1 z - \varphi_2) = 0$ , que possui as seguintes raízes:

$$\lambda_1 = \frac{\varphi_1 + \sqrt{\varphi_1^2 + 4\varphi_2}}{2} \quad \text{e} \quad \lambda_2 = \frac{\varphi_1 - \sqrt{\varphi_1^2 + 4\varphi_2}}{2}$$

- Estudam-se as condições de estacionariedade em dois casos: se na decomposição da equação característica

$(1 - \varphi_1 L - \varphi_2 L^2) = (1 - \lambda_1 L)(1 - \lambda_2 L)$  as raízes  $\lambda$ 's são **reais** ou **complexas**.

- No caso de **raízes reais**, o processo será explosivo se  $\lambda_1 > 1$  e/ou  $\lambda_2 < -1$ .

$$\frac{\varphi_1 + \sqrt{\varphi_1^2 + 4\varphi_2}}{2} > 1, \text{ ou}$$

▪ **Caso 1** :  $\lambda_1 > 1 \rightarrow \sqrt{\varphi_1^2 + 4\varphi_2} > (2 - \varphi_1)$

Como o lado esquerdo será sempre positivo, a desigualdade será sempre satisfeita para  $\varphi_1 > 2$ .

Se  $\varphi_1 < 2$ , então teremos que:

$$\begin{aligned}\sqrt{\varphi_1^2 + 4\varphi_2} &> (2 - \varphi_1) \\ \varphi_1^2 + 4\varphi_2 &> (2 - \varphi_1)^2 \\ \varphi_2 &> 1 - \varphi_1\end{aligned}$$

$$\frac{\varphi_1 - \sqrt{\varphi_1^2 + 4\varphi_2}}{2} < -1, \text{ ou}$$

▪ **Caso 2** :  $\lambda_2 < -1 \rightarrow \sqrt{\varphi_1^2 + 4\varphi_2} < (2 + \varphi_1)$

Como o lado esquerdo será sempre positivo, a desigualdade será sempre satisfeita para  $2 + \varphi_1 < 0$ , ou  $\varphi_1 < -2$ .

Se  $\varphi_1 > -2$ , então teremos que:


$$\sqrt{\varphi_1^2 + 4\varphi_2} > (2 + \varphi_1)$$

$$\varphi_1^2 + 4\varphi_2 > (2 + \varphi_1)^2$$

$$\varphi_2 > 1 + \varphi_1$$

- No caso de **raízes complexas**, sabemos que o modelo será explosivo se  $|\lambda_i| = |R| > 1$ ,  $i = 1, 2$ , isto é, se  $R^2 = -\varphi_2 > 1$ , ou,  $\varphi_2 < -1$ .
- Unindo as condições para os casos real e complexo, é fácil ver que a região de estacionariedade do modelo AR (2) será formada pelos pares  $(\varphi_1, \varphi_2)$ , dentro do triângulo mostrado a seguir:

## Região de estacionariedade de um AR (2)



- Portanto, para um processo AR (2), a condição de estacionariedade é generalizada pela investigação das raízes do polinômio característico, checando se elas localizadas “fora do círculo unitário”<sup>1</sup>.
- Relembrando: para processos AR (1), exigimos como condição de estacionariedade  $|\phi_1| < 1$ , que também pode ser obtida exigindo que as raízes (zeros) do polinômio característico estejam fora do círculo unitário.

<sup>1</sup> Como já se sabe, as raízes podem ser complexas. O círculo unitário nesse caso se refere o conjunto bidimensional dos números no plano complexo que define o círculo centrado na origem de raio unitário.

- A questão que se coloca é como estender a condição de estacionariedade para um processo AR(p) genérico.
- Considere o processo AR(p) definido por:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$$

- Reescrevendo em termos do operador de atraso L e do conseqüente polinômio  $\Phi_p(L)$ .

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) y_t = c + \varepsilon_t$$

$$(1 - \lambda_1 L)(1 - \lambda_2 L) \dots (1 - \lambda_p L) y_t = c + \varepsilon_t$$

em que os  $\lambda$ 's são as raízes do polinômio de grau **p**.

$$f(z) = (z^p - \phi_1 z^{p-1} - \phi_2 z^{p-2} - \dots - \phi_p)$$

- Portanto, investigar as condições de estacionariedade para um processo AR(p) é equivalente a obter as raízes de um polinômio de grau p/ para investigar estacionariedade.
- Definindo as seguintes matrizes:

$$\mathbf{y}_t = \begin{bmatrix} y_t \\ y_{t-1} \\ \vdots \\ y_{t-p+1} \end{bmatrix} \quad \mathbf{F} = \begin{bmatrix} \phi_1 & \phi_2 & \phi_3 & \cdots & \phi_{p-1} & \phi_p \\ 1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 1 & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \cdots & \vdots & \\ 0 & 0 & 0 & \cdots & 1 & 0 \end{bmatrix} \quad \boldsymbol{\varepsilon}_t = \begin{bmatrix} \varepsilon_t \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

- Podemos reescrever a equação de diferenças **escalar** de **ordem p**, como uma equação de diferenças **vetorial** de **ordem 1**, dada por:

$$y_t = F y_{t-1} + \varepsilon_t$$

- Por substituição recursiva, chegamos à:

$$\mathbf{y}_t = \mathbf{F}^t \mathbf{y}_0 + \sum_{i=0}^{t-1} \mathbf{F}^i \boldsymbol{\varepsilon}_{t-i}$$

- O valor esperado do vetor  $\mathbf{y}_t$  será dado por:

$$E(\mathbf{y}_t) = \mathbf{F}^t \mathbf{y}_0$$

- Supondo que a matriz  $F$  possui autovalores reais e distintos, é possível fatorá-la na seguinte forma

$$F = T\Lambda T^{-1}$$

- A matriz  $\Lambda$  é dada por:

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & 0 & \dots & 0 \\ 0 & \lambda_2 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \lambda_p \end{bmatrix}$$

em que os elementos da diagonal são obtidos como soluções da equação determinantal (supondo autovalores reais e distintos):

$$\det(F - \lambda I) = (\lambda^p - \phi_1 \lambda^{p-1} - \phi_2 \lambda^{p-2} - \dots - \phi_p) = 0$$

ou seja, os autovalores da matriz  $F$ .

- Portanto, investigar a condição de estacionariedade de um processo AR (p) é equivalente a **calcular os autovalores da matriz  $F$** , checando a seguinte condição:

$$|\lambda_i| < 1, i = 1, 2, \dots, p.$$



## A Função de Autocorrelação Parcial (FACP)


- Como vimos os processos AR (1) e AR (2) apresentam formas similares para suas FAC's.
- Este comportamento faz com que, dada uma série temporal real, não seja possível identificar precisamente se o modelo gerador da série foi um AR (1) ou AR(2) (ou um AR(p) genérico) a partir da sua FAC estimada (correlograma).
- O que necessitamos é um tipo de função de autocorrelação que seja única para processos AR(p).
- Esta “função” existe e é denominada **Função de Autocorrelação Parcial**, abreviada como **FACP**.
- Para construirmos a FACP devemos, inicialmente, entender por que a FAC falha em identificar a ordem de processos AR(p).
- Por exemplo, considere um processo AR (1):

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t$$


- Como vimos, a FAC desse processo é dada por:

$$\rho(k) = \gamma_k / \gamma_0 = \phi_1^k, k = 1, 2, 3...$$

- O gráfico da FAC (  $0 < \phi_1 < 1$  ) é dada por:



- Observe que, embora o processo tenha apenas dependência explícita entre observações distantes uma unidade de tempo, o gráfico da FAC mostra que a dependência é não nula para observações distantes de 2, 3, 4,... unidades de tempo, embora a magnitude da dependência obviamente decresça.
- Não é difícil entender porque isso ocorre. A dependência entre observações distantes de uma unidade de tempo faz com que, por transitividade, observações distantes **k** unidades de tempo sejam também dependentes linearmente.



- Se desejarmos construir uma medida de “dependência líquida” das observações distantes de  $k$  unidades de tempo, devemos eliminar da dependência total a contribuição dada pelas observações intermediárias, localizadas em  $t-1, t-2, t-3, \dots, t-k+1$ .
- O coeficiente de correlação parcial faz exatamente isso: calcula a correlação entre  $y_t$  e  $y_{t-k}$  eliminando as influências das observações intermediárias  $y_{t-1} y_{t-2} \dots y_{t-k+1}$ .
- Se agruparmos num gráfico estes coeficientes para vários valores de  $k$  obtemos a FACP. Formalmente:

$$\varphi_{kk} = \text{corr}(y_t, y_{t-k} \mid y_{t-1} y_{t-2} \dots y_{t-k+1}), \quad k = 1, 2, 3, \dots$$

- É possível mostrar que cada coeficiente de correlação parcial de ordem  $k$  coincide com o último parâmetro de um modelo  $AR(k)$ .
- A forma mais direta de se obter os coeficientes de autocorrelação parcial é, primeiramente, construir a série  $y_t^* = y_t - \mu$  e então construir autoregressões dessa nova variável nos seus *lags*. Por exemplo:

$$y_t^* = \varphi_{11} y_{t-1}^* + \varepsilon_t$$

$\varphi_{11}$  é portanto o coeficiente de autocorrelação parcial de ordem 1 para uma série, já que não há valores entre as duas variáveis (já que elas estão separadas por apenas um *lag*).

- Avançando mais um *lag* e formando um polinômio autorregressivo de segunda ordem, temos:

$$y_t^* = \varphi_{21}y_{t-1}^* + \varphi_{22}y_{t-2}^* + \varepsilon_t$$

- Nesse caso,  $\varphi_{22}$  é o coeficiente de correlação parcial entre  $y_t$  e  $y_{t-2}$ , isto é, é o efeito líquido da variável  $y_{t-2}$  em  $y_t$  **controlando** pela variável  $y_{t-1}$ . Pode-se mostrar que ele será dado por:

$$\varphi_{22} = \text{corr}(y_t, y_{t-2} | y_{t-1}) = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$$

onde  $\rho_k = \text{corr}(y_t, y_{t-k})$ ,  $k = 1, 2, \dots$

Prova: a FAC de um processo AR(2) é dada por:

$$\rho_k = \varphi_1 \rho_{k-1} + \varphi_2 \rho_{k-2} \quad k = 1, 2, \dots$$

Fazendo  $k = 1$  e  $k = 2$  na expressão acima, chegamos à:

$$\begin{aligned} \rho_1 &= \varphi_1 + \varphi_2 \rho_1 \\ \rho_2 &= \varphi_1 \rho_1 + \varphi_2 \end{aligned} \quad \text{ou em notação matricial:}$$

$$\begin{bmatrix} \rho_1 \\ \rho_2 \end{bmatrix} = \begin{bmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{bmatrix} \begin{bmatrix} \varphi_1 \\ \varphi_2 \end{bmatrix} \Leftrightarrow \mathbf{p} = \mathbf{P}\boldsymbol{\varphi}, \text{ ou } \boldsymbol{\varphi} = \mathbf{P}^{-1} \mathbf{p}.$$

$$\begin{bmatrix} \varphi_1 \\ \varphi_2 \end{bmatrix} = \frac{1}{1 - \rho_1^2} \begin{bmatrix} 1 & -\rho_1 \\ -\rho_1 & 1 \end{bmatrix} \begin{bmatrix} \rho_1 \\ \rho_2 \end{bmatrix} \Rightarrow \varphi_2 = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2} = \varphi_{22}.$$

- Por extensão, o último coeficiente em um processo AR(3) será o coeficiente de correlação parcial de ordem 3, i.e.,

$$\varphi_{33} = \text{corr}(y_t, y_{t-3} \mid y_{t-1} y_{t-2}).$$

- Esta equivalência permite-nos, facilmente observar que a FACP possui um comportamento único para cada processo AR(p).

- Por exemplo, se o processo “verdadeiro” que está gerando a nossa ST é um AR(1), então:

$$y_t = c + \varphi_1 y_{t-1} + \varepsilon_t$$

- Assim sendo para este processo  $\varphi_{kk}=0$ ,  $k > 1$ , pois todos os últimos coeficientes em modelos AR(k),  $K > 1$ , serão nulos, pois o nosso processo é AR(1).

- Por exemplo, no processo AR(2),  $\varphi_{22} = \varphi_2 = 0$

$$y_t = c + \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \varepsilon_t$$

e assim por diante.

Prova: para um processo AR(2) temos que:

$$\rho_1 = \varphi_1 + \varphi_2 \rho_1$$


$$\rho_2 = \varphi_1 \rho_1 + \varphi_2$$

Como o processo verdadeiro é AR(1), então

$\rho_k = \varphi_1^k$ ,  $k = 1, 2$ . Fazendo  $k=1$  e  $2$ , e substituindo na 2a expressão acima:

$$\varphi_1^2 = \varphi_1^2 + \varphi_2 \Rightarrow \varphi_2 = \varphi_{22} = 0.$$

- Procedimento similar demonstra que  $\varphi_{kk} = 0$ ,  $k = 3, 4, \dots$
- Portanto, a forma da FACP para um processo AR(1) é dada por ( $\varphi_1 > 0$ ) :



- Como seria o gráfico da FACP para um processo AR(3) ?


- Um pouco de reflexão permite-nos concluir que a forma geral da FACP para um processo AR(p) será:

$$\begin{aligned}\varphi_{kk} &\neq 0, \quad k \leq p \\ &= 0, \quad k > p.\end{aligned}$$

- Observe entretanto que esta é a FACP teórica, obtida a partir do modelo.
- A FACP de ordem k estimada a partir de uma ST é obtida estimando-se o último coeficiente de um processo AR(k).
- Se o valor deste coeficiente estiver dentro do intervalo de confiança de 95%, então, ao nível de 5%, não podemos rejeitar a hipótese de que  $\varphi_{kk} = 0$ .
- Por exemplo, para um processo AR(1) gerado artificialmente obtemos as seguintes FAC e FACP estimadas:



Fig. – FAC e FACP estimadas para uma realização do processo AR(1).



- Observe que na FACP teórica a correlação parcial para  $k > 1$  é exatamente zero, enquanto que na FACP estimada não é exatamente zero, mas é estatisticamente não discernível de zero.

## Estimação dos parâmetros

- A estimação dos parâmetros de processos AR pode ser efetuada por **Minimos Quadrados Ordinários** (MQO) ou por **Máxima Verossimilhança** (ML).
- Seja  $\theta = [c, \phi_1, \dots, \phi_p, \sigma^2]'$  o vetor de parâmetros desconhecidos do modelo.
- A idéia básica da estimação via verossimilhança é encontrar um conjunto de valores para os parâmetros desconhecidos do modelo tal que, dada a observação uma amostra com  $T$  observações  $(y_1, y_2, \dots, y_T)$ , a probabilidade de termos observado aquela determinada amostra com os valores escolhidos para os parâmetros é a maior possível. Isto é equivalente a **maximizar a densidade de probabilidade conjunta das observações**.
- O problema a ser resolvido é da maximização da função de verossimilhança:

$$\max L(\theta)$$

- Por definição:

$$L(\theta) = L(\theta | y_1, y_2, \dots, y_T) = f(y_1, y_2, \dots, y_T; \theta)$$

em que  $f(y_1, y_2, \dots, y_T; \theta)$  é a densidade conjunta de probabilidade das observações.

- Para observações dependentes, a densidade conjunta das observações de um processo AR(p) pode ser fatorada como o produto de **densidades condicionais marginais**. A forma geral dessa decomposição é dada por:

$$f(y_T, y_{T-1}, \dots, y_1; \theta) = \left( \prod_{t=1}^T p(y_t | \mathbf{Y}_{t-1}, \theta) \right) \cdot f(y_p, y_{p-1}, \dots, y_1; \theta)$$

em que  $y_p, y_{p-1}, \dots, y_1$  é o conjunto dos **p** valores iniciais e  $p(y_t | \mathbf{Y}_{t-1})$  é a densidade condicional marginal para a observação realizada em  $y_t$ .

- Se assumirmos ainda que o termo aleatório do processo AR(p) cujos parâmetros estamos estimando segue um processo ruído branco (ou seja, gaussiano com média nula e variância constante e igual a  $\sigma^2$ ),  $p(y_t | \mathbf{Y}_{t-1})$  é dado por:

$$p(y_t | \mathbf{Y}_{t-1}) \sim N(c + \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \dots + \varphi_p y_{t-p}, \sigma^2)$$

- Como já dito, a idéia é escolher como estimador de  $\theta$  o valor  $\hat{\theta}$  que maximiza a verossimilhança.
- Por razões práticas, maximiza-se o logaritmo da verossimilhança (a verossimilhança e seu log possuem o mesmo máximo).

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} l(\theta) = \underset{\theta}{\operatorname{argmax}} \ln (L(\theta))$$

- A função de log-verossimilhança pode então ser escrita como:

$$\ln(f(y_T, y_{T-1}, \dots, y_1; \theta)) = \sum_{t=p+1}^T \ln(p(y_t | \mathbf{Y}_{t-1}, \theta)) + \ln(f(y_p, y_{p-1}, \dots, y_1; \theta))$$

- O primeiro termo do lado direito da equação é chamado de **log-verossimilhança condicional**. O segundo termo é chamado de **log-verossimilhança marginal para os valores iniciais**.
- Nos modelos de séries temporais, dois tipos de MLE podem ser estimados:

1) Máxima verossimilhança condicional

Baseia-se na maximização da **log-verossimilhança condicional**, isto é:

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} \sum_{t=p+1}^T \ln(p(y_t | \mathbf{Y}_{t-1}, \theta))$$

## 2. Máxima verossimilhança exata

- Baseia-se na maximização da função de log-verossimilhança na sua forma completa (condicional + marginal para valores iniciais) , isto é:

$$\hat{\theta} = \arg \max_{\theta} \sum_{t=p+1}^T \ln(p(y_t | \mathbf{Y}_{t-1}, \theta)) + \ln(f(y_p, y_{p-1}, \dots, y_1; \theta))$$

- Para um processo AR (1), a máxima verossimilhança **condicional** é dada por:

$$\begin{aligned} l(\theta) &= \log \left( \prod_{t=2}^T \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[ -\frac{1}{2\sigma^2} (y_t - (c - \phi_1 y_{t-1}))^2 \right] \right) = \\ &= \log \left[ \left( \frac{1}{2\pi\sigma^2} \right)^{(T-1)/2} \exp \left[ -\frac{1}{2\sigma^2} \sum_{t=2}^T (y_t - (c - \phi_1 y_{t-1}))^2 \right] \right] = \\ &= -\frac{(T-1)}{2} \log(2\pi) - \frac{(T-1)}{2} \log(\sigma^2) - \sum_{t=2}^T \frac{(y_t - c - \phi_1 y_{t-1})^2}{2\sigma^2} \end{aligned}$$

- Os estimadores de MV são obtidos verificando as seguintes condições de máximo de uma função:

– condição de 1ª ordem:  $\frac{\partial l(\theta)}{\partial \theta_i} = 0$  ,  $i=1,2,\dots,p$  (*necessária*)

– condição de 2ª ordem:  $H = \frac{\partial^2 l(\theta)}{\partial \theta \partial \theta'}$  é *negativa definida* (*suficiente*)

- É fácil de ver que derivando  $l(\theta)$  em termos de  $c$ ,  $\phi_1$  e  $\sigma^2$  e igualando a zero, encontramos:

$$\hat{c} = \bar{y}_{t,T-1} - \hat{\phi}_1 \bar{y}_{t-1,T-1}, \text{ onde } \bar{y}_{s,T-1} = \frac{\sum_{t=2}^T y_s}{(T-1)}$$

$$\hat{\phi}_1 = \frac{\sum_{t=2}^T y_t \sum_{t=2}^T y_{t-1} - (T-1) \sum_{t=2}^T y_t y_{t-1}}{\left( \sum_{t=2}^T y_{t-1} \right)^2 - (T-1) \sum_{t=2}^T y_{t-1}^2}$$

$$\hat{\sigma}^2 = \frac{1}{T-1} \sum_{t=2}^T [y_t - (\hat{c} + \hat{\phi}_1 y_{t-1})]^2$$

- Não é difícil observar que estes estimadores seriam também obtidos ao minimizar a soma dos quadrados dos erros de previsão, isto é:

$$\varepsilon_t = y_t - \hat{y}_{t|t-1} = y_t - (c + \phi_1 y_{t-1})$$

$$Q(c, \phi_1) = \sum_{t=2}^T \varepsilon_t^2 = \sum_{t=2}^T [y_t - (c + \phi_1 y_{t-1})]^2.$$

- Este critério de otimização é chamado de Mínimos Quadrados Ordinários e será equivalente à Máxima Verossimilhança Condicional se  $\varepsilon_t \sim N(0, \sigma^2)$ .
- Ainda para o processo AR(1), podemos escrever a máxima verossimilhança **exata**, dada pela da log-verossimilhança condicional deduzida acima somada a densidade marginal para  $y_1$ . Dado que:

$$p(y_1|y_0) \sim N\left(\frac{c}{(1-\phi_1)}, \frac{\sigma^2}{1-\phi_1^2}\right)$$

tem-se que:

$$f(y_1, \boldsymbol{\theta}) = \left(2\pi \frac{\sigma^2}{1-\phi_1^2}\right)^{1/2} \exp\left[-\left(\frac{1-\phi_1^2}{2\sigma^2}\right)\left(y_1 - \frac{c}{1-\phi_1}\right)^2\right]$$

- Note que a função de log-verossimilhança exata é não linear nos parâmetros. Portanto, não mais será possível obter soluções analíticas para os estimadores de MV, e neste caso não haverá equivalência entre os estimadores de MQO e os de MV. Neste caso, a solução para o problema de maximização é usualmente encontrada pelo uso de métodos numéricos.

- Para  $T$  suficientemente grande, a distribuição dos estimadores de MV condicionais pode ser aproximada pela seguinte distribuição:

$$\hat{\boldsymbol{\theta}} \sim N(\boldsymbol{\theta}, T^{-1}\mathbf{I}^{-1})$$

em que  $\mathbf{I}$  é a matriz de informação de Fisher definida por:

$$\mathbf{I} = -E\left(\frac{\partial^2 L(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'}\right)$$

- A partir deste resultado é possível então realizar testes de hipótese para investigar a significância dos coeficientes de um modelo AR

Included observations: 299  
Convergence achieved after 3 iterations

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-0.002485	0.326664	-0.007607	0.9939
AR(1)	0.629202	0.045294	13.89160	0.0000
R-squared	0.393849	Mean dependent var		0.016307
Adjusted R-squared	0.391808	S.D. dependent var		2.685514
S.E. of regression	2.094343	Akaike info criterion		4.323024
Sum squared resid	1302.723	Schwarz criterion		4.347776

p-valor para o teste de  $H_0: \phi_1 = 0$



- Para um processo AR(p) genérico, condicional em  $y_1, y_2, \dots, y_p$ , o log da verossimilhança será dada por:

$$l(\boldsymbol{\theta}) = -\frac{(T-p)}{2} \log(2\pi) - \frac{(T-p)}{2} \log(\sigma^2) - \sum_{t=p+1}^T \frac{[y_t - (c - \sum_{i=1}^p \phi_i y_{t-i})]^2}{2\sigma^2}$$

- Como esperado, nesta situação os estimadores de MV para  $c$  e os  $\phi$ 's são equivalentes aos de MQO.