

MA (Moving average)

Processo MA (1)

- Considere o processo MA (1)

$$y_t = c + \theta_1 \varepsilon_{t-1} + \varepsilon_t$$

em que ε_t é um ruído branco Gaussiano $N(0, \sigma^2)$.

- Os seus momentos **condicionais** são dados por :
 - $E(y_t | \mathbf{Y}_{t-1}) = c + \theta_1 \varepsilon_{t-1}$
 - $\text{Var}(y_t | \mathbf{Y}_{t-1}) = \sigma^2$
 - $f(y_t | \mathbf{Y}_{t-1}) \sim N(c + \theta_1 \varepsilon_{t-1}, \sigma^2)$
- Os momentos **incondicionais** podem ser obtidos de forma direta:

$$E(y_t) = (c + \theta_1 \varepsilon_{t-1} + \varepsilon_t) = c = \mu$$

$$\begin{aligned} \text{Var}(y_t) &= E(y_t - \mu)^2 = E[(\theta_1 \varepsilon_{t-1} + \varepsilon_t)]^2 \\ &= \sigma^2(1 + \theta_1^2) \\ &= \gamma(0) \end{aligned}$$

Invertibilidade de processos MA (1)

- Um modelo de séries temporais é dito **invertível** se é capaz de expressar o distúrbio aleatório corrente como função do valor corrente e de valores passados da série e dos parâmetros do modelo:

$$\varepsilon_t = g(y_t, \theta, Y_{t-1})$$

- Modelos AR são por construção invertíveis. (verifique !)
- Já para os processos MA (1), tem-se:

$$\begin{aligned} y_t &= c + \theta_1 \varepsilon_{t-1} + \varepsilon_t = \mu + (1 + \theta_1 L) \varepsilon_t \\ (1 - (-\theta_1) L) \varepsilon_t &= y_t - \mu \end{aligned}$$

- Dividindo ambos os lados da última equação por $(1 - (-\theta_1) L)$, chega-se a:

$$\varepsilon_t = (1 - (-\theta_1) L)^{-1} (y_t - \mu)$$

- Sob as hipóteses de que $|(-\theta_1)| < 1$ e $t \rightarrow \infty$, tem-se que:

$$(1 - (-\theta_1) L)^{-1} = \sum_{j=0}^{\infty} (-\theta_1)^j L^j$$

e a equação anterior pode ser reescrita como:

$$\varepsilon_t = \sum_{j=0}^{\infty} (-\theta_1)^j (y_{t-j} - \mu) \sim \text{AR}(\infty)$$

- Note que a condição de invertibilidade de um processo MA (1) equivale à condição de estacionariedade de um processo AR (1). Note também que um processo MA(1) é equivalente a um processo AR (∞).

Função de Autocorrelação para processos MA (1)

As equações do processo para os tempos k e $t-k$ são dadas por:

$$y_t = \mu + \theta_1 \varepsilon_{t-1} + \varepsilon_t$$

$$y_{t-k} = \mu + \theta_1 \varepsilon_{t-k-1} + \varepsilon_{t-k}$$

Avaliando o valor esperado do produto das equações:

$$\begin{aligned} \gamma(k) &= E[(y_t - \mu)(y_{t-k} - \mu)] = \\ &= E[(\theta_1 \varepsilon_{t-1} + \varepsilon_t)(\theta_1 \varepsilon_{t-k-1} + \varepsilon_{t-k})] = \\ &= \theta_1^2 E(\varepsilon_{t-1} \varepsilon_{t-k-1}) + \theta_1 E(\varepsilon_{t-1} \varepsilon_{t-k}) + \theta_1 E(\varepsilon_t \varepsilon_{t-k-1}) + E(\varepsilon_t \varepsilon_{t-k}) \end{aligned}$$

- Observe que para $k > 1$, a expressão encontrada acima é nula, pois ε_t é um ruído branco que portanto não exibe correlação com seus próprios lags. Para $k = 1$, tem-se:

$$\gamma(1) = \theta_1 \sigma^2$$

- Finalmente, a FAC para processos MA puros é dada por:

$$\rho(k) = \gamma(k) / \gamma(0) = \begin{cases} \frac{\theta_1}{(1 + \theta_1^2)} , & k = 1 \\ 0 & , k > 1 \end{cases}$$

- Essa é uma **característica geral de processos MA puros de ordem p**:

a autocorrelação para lags **maiores que p** é sempre **nula**, o que permite identificarmos esse tipo de modelo simplesmente através do **correlograma** da série, como veremos adiante.

- Observe também que não há necessidade de imposição de nenhuma restrição sobre os parâmetros para que o modelo seja assintoticamente estacionário. Os modelos MA são ditos **trivialmente estacionários**.

FACP para processos MA (1)

- Dado que um processo MA (1) pode ser escrito como um modelo autoregressivo de ordem infinita, segue que a função de autocorrelação parcial de processo MA (1) terá **decaimento exponencial** ou de **senóide amortecida**, dependendo da raiz do seu polinômio característico.

Previsão em processos MA (1)

- A previsão pontual é dada por:

$$\begin{aligned}y_t &= c + \theta_1 \varepsilon_{t-1} + \varepsilon_t \\y_{t+k} &= c + \theta_1 \varepsilon_{t+k-1} + \varepsilon_{t+k}, \quad k=1,2,\dots \\ \hat{y}_{t+k|t} &= E(y_{t+k} | Y_t) \\ &= \mu + \theta_1 E(\varepsilon_{t+k-1} | Y_t) + E(\varepsilon_{t+k} | Y_t) \\ &= \mu + \theta_1 E(\varepsilon_{t+k-1} | Y_t) \\ &= \begin{cases} \mu + \theta_1 \varepsilon_t, & k = 1 \\ \mu, & k > 2 \end{cases}\end{aligned}$$

- Observe que na prática ε_t deve ser estimado, o que pode ser feito através da expressão AR para o processo MA.
- De modo semelhante o que vimos para processo autoregressivos, podemos construir um intervalo de confiança para essa previsão:

$$\begin{aligned} \text{MSE}(\hat{y}_{t+k|t}) &= E[(y_{t+k} - \hat{y}_{t+k|t})^2 | \mathbf{Y}_t] \\ &= \begin{cases} \sigma^2 & , k=1 \\ (1 + \theta_1^2) \sigma^2 & , k > 1 \end{cases} \end{aligned}$$

possibilitando a construção do IC para previsão de k passos:

$$\hat{y}_{t+k|t} \pm z^{\alpha/2} \sqrt{\text{MSE}(\hat{y}_{t+k|t})}$$

Estimação dos parâmetros

- A estimação dos parâmetros desconhecidos de um modelo MA(1), $\theta = (\mu, \theta_1, \sigma^2)$, $\mu \in \mathbb{R}$, $\theta_1 \in (-1, 1)$, $\sigma^2 \in \mathbb{R}^+$, é efetuada por **máxima verossimilhança**, não podendo ser realizada via mínimos quadrados, como veremos a seguir.
- Para um processo MA (1), assumindo que o termo aleatório segue um processo ruído branco, a densidade condicional de y_t é dada por:

$$p(y_t | \mathbf{Y}_{t-1}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2} (y_t - (\mu + \theta_1 \varepsilon_{t-1}))^2\right] \quad t = 1, 2, \dots, T$$

em que

$$\begin{aligned} \varepsilon_t &= y_t - (\mu + \theta_1 \varepsilon_{t-1}) \\ &= (y_t - \mu) - \theta_1 (y_{t-1} - \mu) + \theta_1^2 (y_{t-2} - \mu) + \dots + (-1)^t \theta_1^t \varepsilon_0 \end{aligned}$$

- Admitindo que o modelo é invertível, $|\theta_1| < 1$ e se $t \rightarrow \infty$, esta condição é equivalente a assumir $\varepsilon_0 = 0$.
- Assim sendo a log-verossimilhança condicional em $\varepsilon_0 = 0$, toma forma:

$$\begin{aligned}
 l(\theta) &= \ln \left(\prod_{t=1}^T p(y_t | Y_{t-1}, \varepsilon_0 = 0) \right) \\
 &= \ln \left(\prod_{t=1}^T \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2\sigma^2} (y_t - (\mu + \theta_1 \varepsilon_{t-1}))^2 \right] \right) \\
 &= \ln \left(\left(\frac{1}{2\pi\sigma^2} \right)^{T/2} \exp \left(-\frac{1}{2\sigma^2} \sum_{t=1}^T \varepsilon_t^2(\mu, \theta_1) \right) \right) \\
 &= -\frac{T}{2} \ln(2\pi) - \frac{T}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=1}^T \varepsilon_t^2(\mu, \theta_1)
 \end{aligned}$$

- A aplicação das condições de 1ª ordem fornece as equações para se obter os estimadores de MV:

$$\partial l / \partial \sigma^2 = 0, \quad \partial l / \partial \theta_1 = 0 \quad \text{e} \quad \partial l / \partial \mu = 0$$

(as derivadas devem ser avaliadas nos valores estimados dos outros parâmetros, caso se aplique.)

- Supondo que dispomos dos estimadores de MV para μ e θ_1 , o estimador para σ^2 é facilmente obtido, possuindo expressão:

$$\hat{\sigma}^2 = \frac{1}{T} \sum_{t=1}^T \hat{\varepsilon}_t^2(\hat{\mu}, \hat{\theta}_1)$$

- Entretanto, é fácil checar que para os dois outros parâmetros as equações não apresentarão solução analítica, necessitando assim de algoritmo de otimização numérica para a sua solução.
- Observe que maximizar a função de verossimilhança equivale a minimizar a soma do quadrados dos resíduos.

Generalização para processos MA(q)

- Um processo MA(q) é definido por:

$$y_t = \mu + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma^2)$$

$$y_t = \mu + (1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q) \varepsilon_t$$

$$y_t - \mu = \Theta_q(L) \varepsilon_t$$

$$\Theta_q(L) = (1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q)$$

- A distribuição condicional é dada por:

$$f(y_t | \mathbf{Y}_{t-1}) \sim N(\mu + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}, \sigma^2)$$

- A distribuição incondicional é dada por:

$$f(y_t) \sim N(\mu, \sigma^2(1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2))$$

já que:

$$E(y_t) = E(\mu + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t) = \mu$$

$$\begin{aligned} \text{Var}(y_t) &= E(y_t - \mu)^2 = E(\theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t)^2 \\ &= \sigma^2(1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2) = \gamma(0) \end{aligned}$$

- A autocovariância será dada por:

$$\begin{aligned} \gamma_k &= E[(y_t - \mu)(y_{t-k} - \mu)] \\ &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q})(\varepsilon_{t-k} + \theta_1 \varepsilon_{t-k-1} + \dots + \theta_q \varepsilon_{t-k-q})] \\ &= \begin{cases} \sigma^2(\theta_k + \theta_{k+1}\theta_1 + \dots + \theta_q \theta_{q-k}) & 0 < k \leq q \\ 0 & k > q \end{cases} \end{aligned}$$

- Portanto, a função de autocorrelação será dada por:

$$\rho_k = \begin{cases} \frac{(\theta_k + \theta_{k+1}\theta_1 + \dots + \theta_q \theta_{q-k})}{(1 + \theta_1^2 + \dots + \theta_q^2)} & 0 < k \leq q \\ 0 & k > q \end{cases}$$

- Um pouco de reflexão nos diz que a condição de invertibilidade de um processo MA pode ser investigada através das raízes do polinômio MA:

$$(1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q) \varepsilon_t = y_t - \mu$$

$$(1 - \lambda_1 L)(1 - \lambda_2 L) \dots (1 - \lambda_p L) \varepsilon_t = y_t - \mu$$

em que os λ 's são as raízes do polinômio de grau q

$$f(z) = (z^p + \theta_1 z^{p-1} + \theta_2 z^{p-2} + \dots + \theta_q)$$

- Portanto, teremos que obter as raízes de um polinômio de grau q para investigar invertibilidade de um processo MA.
- Na prática, a mesma metodologia utilizada para investigar a estacionariedade de um processo AR(p) pode ser utilizada para investigar a invertibilidade de um processo MA(q).
- Define-se a matriz F :

$$\mathbf{F} = \begin{bmatrix} \theta_1 & \theta_2 & \theta_3 & \dots & \theta_q \\ 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \dots & \vdots \\ 0 & 0 & 0 & \dots & 0 \end{bmatrix}$$

- Investigar a condição de invertibilidade de um processo MA(q) é equivalente a calcular os autovalores da matriz F , checando a condição:

$$|\lambda_i| < 1, i = 1, 2, \dots, q$$

- Quanto à estimação dos parâmetros do modelo, temos que a densidade condicional é dada por:

$$p(y_t | \mathbf{Y}_{t-1}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2} \varepsilon_t^2\right] \quad t = 1, 2, \dots, T$$

$$\varepsilon_t = y_t - (\mu + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}).$$

- Assim sendo a log-verossimilhança condicional em $\varepsilon_0 = \varepsilon_{-1} = \varepsilon_{-2} = \dots = \varepsilon_{-q} = 0$, toma forma:

$$l(\theta) = -\frac{T}{2} \ln(2\pi) - \frac{T}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=1}^T \varepsilon_t^2(\mu, \theta_1, \theta_2, \dots, \theta_q), \text{ com}$$

$$\varepsilon_0 = \varepsilon_{-1} = \varepsilon_{-2} = \dots = \varepsilon_{-q+1} = 0.$$

- Como já indicado no caso de processos MA (1), métodos numéricos de otimização são utilizados para resolver as condições de primeira ordem e obter as estimativas dos parâmetros do modelo.

Dualidade AR x MA:

A dualidade entre os processos AR e MA se reproduz nas “assinaturas” reveladas na FAC e na FACP:

	Processo AR(P)	Processo MA(q)
FAC	Decai exponencialmente ou como senóide amortecida	Corte além da ordem q do processo: $\rho_k \neq 0, \quad k = 1, 2, \dots, q$ $\rho_k = 0, \quad k = q + 1, q + 2, \dots$
FACP	Corte além da ordem p do processo: $\phi_{kk} \neq 0, \quad k = 1, 2, \dots, p$ $\phi_{kk} = 0, \quad k = p + 1, p + 2, \dots$	Decai exponencialmente ou como senóide amortecida

Identificação dos processos:

- Se a FAC decai exponencialmente, é um indício de que o processo pode ser AR. Nesse caso, a FACP ajuda a determinar a ordem do processo.
- Se a FAC apresenta um corte abrupto depois de poucas defasagens, é um indício de que o processo pode ser MA. Isso se confirma se a FACP decai exponencialmente.

Significância estatística da FAC e da FACP

- Viu-se que a identificação de um modelo ARMA depende das características apresentadas pelas FAC e FACP.
- Na prática só dispomos de *estimativas amostrais* dessas duas funções, obtidas a partir dos dados da ST sendo investigada.
- Como dispomos de estimativas, que são variáveis aleatórias, devemos efetuar um teste de significância, com a hipótese nula de que os valores populacionais da FAC e FACP são nulos.
- Para grandes amostras, pode-se mostrar que, sob a hipótese nula de um ruído branco:


$$\text{FAC: } r_k \sim N(0, 1/T)$$

$$\text{FACP: } \hat{\phi}_{kk} \sim N(0, 1/T)$$

- Assim, um intervalo de confiança de aproximadamente 95% para uma autocorrelação ou autocorrelação parcial amostral é dado por $\pm 2/\sqrt{T}$. Se r_k ou $\hat{\phi}_{kk}$ estiver fora do intervalo, é uma indicação de processo AR ou MA presente.

Exemplo

- Qual a ordem de auto-regressão da série de exportações trimestrais brasileiras de derivados de petróleo (1977:1 a 1999:3)?
- A FAC estimada sugere um processo AR puro, pois ela decai exponencialmente. Por outro lado, sua FACP apresenta (ver figura) um corte em $k = 1$:



- No entanto, o gráfico mostra autocorrelações parciais diferentes de zero (embora menores) em $k > 1$. Será mesmo um processo AR (1) ou de ordem superior?

$$N = 91 \Rightarrow 2/\sqrt{91} = 0,21$$

- Como a única autocorrelação parcial fora do intervalo $\pm 0,21$ é a primeira, podemos concluir ao nível de aproximadamente 5% que o processo é AR (1).
- A idéia é a mesma para identificar um MA(q), mas o teste se faz sobre as autocorrelações (não parciais).